

МАТЕМАТИКА ДЛЯ ПРОГРАММИРОВАНИЯ

3 курс ответы егэ без смс и регистрации взлом apk (мод - повышенная стипендия+много денег+много жизней)

ПОЛЕЗНЫЕ МАТЕРИАЛЫ

материалы облако: <https://cloud.mail.ru/public/9vhg/g3vRjBAYW>

плейлист лекций на трубе:

https://www.youtube.com/playlist?list=PLD1F_9ie4T3nwJpCsEjIFjLP7o4mP3-i

плейлист лекций на вк видео:

https://vkvideo.ru/video-207663218_456239019?pl=-207663218_2

мы обязательно всё сдадим без долгов!

Вы сказали всем, что у меня нет шансов? Что у меня кроме молитвы ничего нет? БОЛВАН! Мне больше ничего и не надо!!!

ОГЛАВЛЕНИЕ

ПОЛЕЗНЫЕ МАТЕРИАЛЫ.....	1
ОГЛАВЛЕНИЕ.....	1
ЗАНЯТИЕ №1.....	8
1. Общие свойства интеллектуальных алгоритмов. Определение модели. Свойство обучаемости.....	8
2. Общие свойства интеллектуальных алгоритмов. Подготовка данных для обучения моделей. Основные этапы.....	9
3. Общие свойства интеллектуальных алгоритмов. Подготовка данных для обучения моделей. Методики Data collection.....	10
ЗАНЯТИЕ №2.....	12
4. Дискриминативные технологии искусственного интеллекта. Принцип работы. Детерминированные и Стохастические модели. Проблемы разделения.....	12
5. Дискриминативные технологии искусственного интеллекта.	

Основные разделы дискриминативного искусственного интеллекта. Предварительная обработка данных. Поиск ассоциативных правил в задачах дискриминативного и генеративного искусственного интеллекта.....	15
6. Дискриминативные технологии искусственного интеллекта. Основные разделы дискриминативного искусственного интеллекта. Классификация и регрессия в задачах дискриминативного и генеративного искусственного интеллекта.....	19
7. Дискриминативные технологии искусственного интеллекта. Основные разделы дискриминативного искусственного интеллекта. Кластеризация как основа генеративного искусственного интеллекта..	21
ЗАНЯТИЕ №3.....	23
8. Генеративные технологии искусственного интеллекта. Генерация табличных данных. Принцип работы. Описание основных разделов.....	23
9. Генеративные технологии искусственного интеллекта. Генерация табличных данных. Продукционные правила. Децентрализованная генерация. Построение онтологий знаний.....	24
10. Генеративные технологии искусственного интеллекта. Генерация табличных данных. Машинное обучение. Первое поколение. Модели гауссовых смесей. Байесовские сети.....	28
11. Генеративные технологии искусственного интеллекта. Генерация табличных данных. Машинное обучение. Первое поколение. Модель Copula. Актуальные модели. Метод SMOTE.....	31
12. Генеративные технологии искусственного интеллекта. Генерация табличных данных. Искусственные нейронные сети. Первое поколение. Применение CNN и RNN в генеративных задачах.....	34
ЗАНЯТИЕ №4.....	36
13. Генеративные технологии искусственного интеллекта. Генерация табличных данных. Искусственные нейронные сети. Актуальные модели. TGAN. CTGAN. Отличие от стандартного GAN – адаптация под табличные данные. Генератор. Дискриминатор. Классификатор.....	36
14. Генеративные технологии искусственного интеллекта. Генерация табличных данных. Искусственные нейронные сети. Актуальные модели. TVAE. Отличие от стандартного VAE – адаптация под табличные данные. Энкодер. Декодер. Латентное пространство....	36
15. Генеративные технологии искусственного интеллекта. Генерация табличных данных. Искусственные нейронные сети. Актуальные модели. TabDDPM. Отличие от стандартной DPM – адаптация под табличные данные. Прямой и обратный процесс	

диффузии. Непрерывная релаксация и Квантильный трансформер.....	36
16. Генеративные технологии искусственного интеллекта. Генерация табличных данных. Метрики качества. Объективные метрики. TSTR. Методика разрешённых и запрещённых условий.....	37
17. Генеративные технологии искусственного интеллекта. Генерация табличных данных. Метрики качества. Субъективные метрики. SHAP. SDR. Статистические меры.....	37
18. Генеративные технологии искусственного интеллекта. Генерация табличных данных. Аугментация табличных данных (причины, особенности и проблемы). Модельная, нейронная и статистическая аугментация табличных данных.....	38
19. Генеративные технологии искусственного интеллекта. Генерация мультимедийных данных. Описание основных разделов. Особенности разных мультимедийных модальностей (изображений, видео и звука).....	39
20. Генеративные технологии искусственного интеллекта. Генерация мультимедийных данных. Архитектура GAN. Генератор. Дискриминатор. Пайплайн обучения. Проблема коллапса режимов.....	39
21. Генеративные технологии искусственного интеллекта. Генерация мультимедийных данных. VAE. Отличие VAE от стандартного AE. Энкодер. Декодер. Латентное пространство. Функция ошибок VAE.....	40
22. Генеративные технологии искусственного интеллекта. Генерация мультимедийных данных. DPM. Пайплайн обучения. Прямой и обратный процессы диффузии.....	43
23. Генеративные технологии искусственного интеллекта. Генерация мультимедийных данных. Модели авторегрессии. Авторегрессионные свойства данных. Модели на основе пикселей и модели на основе токенов. Процесс обучения модели.....	44
24. Генеративные технологии искусственного интеллекта. Генерация мультимедийных данных. Метрики моделей генерации мультимедиа. Дискриминативные модели для TSTR. Субъективные метрики. FID, IS, PSNR.....	44
25. Генеративные технологии искусственного интеллекта. Генерация мультимедийных данных. Специфические модели генерации звука. HiFi-GAN. Вокодеры. Мэл-спектрограмма.....	45
26. Генеративные технологии искусственного интеллекта. Генерация мультимедийных данных. Специфические модели генерации звука. WaveNet. Факторизация распределения. Метрики качества генерации звука. MCD. PESQ.....	45
27. Генеративные технологии искусственного интеллекта.	

Генерация мультимедийных данных. Специфические модели генерации видео. Векторно-квантованные автоэнкодеры. Отличия процесса обучения от классических VAE.....	45
28. Генеративные технологии искусственного интеллекта. Генерация мультимедийных данных. Специфические модели генерации видео. Общая концепция. Метрики оценки качества видео. FVD.....	46
ЗАНЯТИЕ №5.....	46
29. Генеративные технологии искусственного интеллекта. Обработка естественного языка (задача NLP). Описание основных разделов. Виды языковых моделей. Задачи, решаемые разными видами языковых моделей.....	46
30. Генеративные технологии искусственного интеллекта. Обработка естественного языка (задача NLP). Языковые модели первого поколения. Токенизаторы. One-hot encoding. BPE. WordPiece. Типичные задачи.....	47
31. Генеративные технологии искусственного интеллекта. Обработка естественного языка (задача NLP). Малые (классические) языковые модели. Word2Vec. Seq2Seq. Типичные задачи.....	49
32. Генеративные технологии искусственного интеллекта. Обработка естественного языка (задача NLP). Большие языковые модели. Трансформер. Обзор видов трансформеров. Специфические задачи трансформеров.....	51
33. Генеративные технологии искусственного интеллекта. Обработка естественного языка (задача NLP). Компоненты архитектуры трансформера. Механизм внимания и виды внимания. Дообучение языковых моделей. Fine-Tuning. PEFT. Retraining.....	54
34. Генеративные технологии искусственного интеллекта. Обработка естественного языка (задача NLP). Большие языковые модели. Encoder-only трансформеры. BERT. Особенности архитектуры, обучения и регуляризации. Типичные задачи.....	56
35. Генеративные технологии искусственного интеллекта. Обработка естественного языка (задача NLP). Большие языковые модели. Decoder-only трансформеры. GPT. Особенности архитектуры, обучения и регуляризации. Типичные задачи.....	59
36. Генеративные технологии искусственного интеллекта. Обработка естественного языка (задача NLP). Большие языковые модели. Encoder-Decoder трансформеры. T5. Особенности архитектуры, обучения и регуляризации. Типичные задачи.....	60
37. Генеративные технологии искусственного интеллекта. Обработка естественного языка (задача NLP). Модификация языковых моделей. Аугментация данных. Промпт-инжиниринг. RAG.....	63

38. Генеративные технологии искусственного интеллекта. Обработка естественного языка (задача NLP). Метрики оценки качества языковых моделей. Стандартные метрики классификации. TF-IDF. Perplexity. BLEU.....	65
ЗАНЯТИЕ №6.....	68
39. Эволюционные вычисления. Системы интеллектуальных агентов. Агенты как искусственный интеллект. Свойства агентов. BDI-модель. Виды интеллектуальных агентов.....	69
40. Эволюционные вычисления. Системы интеллектуальных агентов. Агенты как искусственный интеллект. Моно- и мультиагентные системы, их архитектуры. Задачи интеллектуальных агентов.....	73
41. Эволюционные вычисления. Системы интеллектуальных агентов. Агенты как инструменты машинного обучения. Общее определение. Свойства генеративного ИИ-агента.....	75
42. Эволюционные вычисления. Системы интеллектуальных агентов. Задачи и инструменты NLP, text-to-text.....	77
43. Эволюционные вычисления. Системы интеллектуальных агентов. Задачи и инструменты text-to-image, text-to-audio/voice, text-to-video...	79
44. Эволюционные вычисления. Системы интеллектуальных агентов. Задачи и инструменты text-to-sql.....	80
ПРАКТИЧЕСКИЕ ЗАДАНИЯ.....	81
45. Опишите план работ и пример использованных методов при предварительной обработке малого разреженного табличного набора данных с наличием экстремальных, сильно отклоняющихся от медианы, моды и средних значений атрибутов (признаков).....	81
46. Приведите пример инструментов, которые необходимо применить, чтобы создать искусственный табличный набор данных, содержащий преимущественно категориальные признаки, и оценить качество созданного набора данных с помощью методики TSTR и субъективных метрик.....	82
47. Приведите пайплайн анализа табличного набора данных, в котором нужно построить дашборд с отображением взаимной зависимости числовых признаков и их нерегулярностей, баланс классов категориальных признаков, а также общий график распределения всех признаков в двумерном пространстве.....	84
48. Приведите пример инструментов и пайплайн, которые необходимо применить, чтобы создать искусственный табличный набор данных, содержащий преимущественно числовые признаки с высокой локальной плотностью данных, и проверить созданный набор данных с помощью методики TSTR и субъективных метрик.....	85

49. Приведите пример инструментов и пайплайн, которые необходимо применить, чтобы создать искусственные похожие друг на друга изображения или видео в реальном времени. Опишите объективные и субъективные метрики, которые вы будете применять для оценки качества генерации..... 87
50. Приведите пример инструментов и пайплайн, которые необходимо применить, чтобы отредактировать существующие изображения или видео или создать искусственные, являющиеся генерализированной интерпретацией обучающей выборки. Опишите объективные и субъективные метрики, которые вы будете применять для оценки качества..... 88
51. Приведите пример инструментов и пайплайн для создания фотореалистичных искусственных изображений или видео в условиях достаточного количество видео- и оперативной памяти для обучения. Опишите объективные и субъективные метрики, которые вы будете применять для оценки качества..... 90
52. Приведите пример инструментов и пайплайн для создания аудиофайла высокого качества, содержащего синтетическую речь. Опишите объективные и субъективные метрики, которые вы будете применять для оценки качества..... 91
53. Приведите пример инструментов и пайплайн для создания аудиофайла, содержащего звуки окружающего мира или музыку (без голоса). Опишите объективные и субъективные метрики, которые вы будете применять для оценки качества..... 93
54. Приведите пример инструментов и пайплайн для создания приложения, выполняющего классификацию и сегментацию текста в локальной базе данных в небольшой корпоративной системе в организации, не имеющий возможность устанавливать локально большие языковые модели из-за отсутствия графических серверов и отсутствия возможности их закупки и не имеющей возможность подключаться к внешним сервисам языковых моделей из-за соблюдения корпоративной тайны и неразглашения персональных данных (выборка документов небольшая и однородная)..... 94
55. Приведите пример инструментов и пайплайн для создания приложения, выполняющего извлечение именованных сущностей и поиска ответов на вопросы пользователя в текстовых документах организации, имеющей достаточные вычислительные мощности для запуска небольших локальных языковых моделей, но не имеющих возможности использовать внешние сервисы языковых моделей из-за соблюдения корпоративной тайны и неразглашения персональных данных сотрудников..... 96

56. Приведите пример инструментов и пайплайн для создания корпоративного чат-бота в условиях отсутствия возможности выходить в глобальную сеть. Чат-бот должен уметь бороться с галлюцинациями и с высокой точностью находить конкретные пункты в корпоративных документах. Вычислительной мощности серверного оборудования организации достаточно для запуска нескольких больших языковых моделей с менее 10 миллиардов параметров, либо одной большой на 30+ миллиардов.

Так как речь идет про чатбот, то здесь подойдет модель Decoder-only. Либо несколько моделей поменьше, либо одна крупная..... 97

57. Приведите пример инструментов и пайплайн для создания системы суммаризации и перевода текста для организации, изучающей исторические тексты античного и более ранних периодов. Ограничений по вычислительным мощностям и выхода в глобальную сеть нет. Модель должна уметь вести диалог от лица специалиста в предметной области и дообучаться на новых текстах – в том числе других культурных и языковых групп.

Какими-то инструментами придется модернизировать, модифицировать, улучшить эту языковую модель. (перед 5 занятием об этом говорили)..... 99

58. Приведите пример инструментов и пайплайн для создания системы, способной самостоятельно изучать источники и создавать мультимедийный контент одной модальности на основе запроса пользователя..... 100

59. Приведите пример инструментов и пайплайн для создания системы, работающей в условиях слабоструктурированных запросов пользователей и генерации контента разной модальности. Система сама должна находить источники, предлагать несколько вариантов, а менее релевантные отсекай сама в процессе генерации..... 102

60. Приведите пример инструментов и пайплайн для создания системы, способной в зависимости от запроса пользователя выполнять задачи разных модальностей, но только по одной модальности за один запрос пользователя. К задачам могут относиться text-to-text, text-to-sql и text-to-code..... 103

ЗАНЯТИЕ №1

1. Общие свойства интеллектуальных алгоритмов. Определение модели. Свойство обучаемости.

Общие свойства -

1. Наличие Модели

Это могут быть скрытые марковские модели, DNN, random forest или GMM (Гауссовских смесей), у них может быть разная математика, разные алгоритмы (в их основе, они по разному учаться, служат для разных задач. То есть у них всех есть интеллектуальная модель, которая в процессе способна что-то изменять.

Модель - математическая формула (часто взвешенная) - формальное описание процесса, объекта или явления предметной области.

Формализмы - абстрагирование от смысла с чёткой структурой (важен не смысл, а форма)

Предметная область - часть реального мира которая подлежит изучению, моделированию или автоматизации.

Алгоритм - последовательность действия, направленная на достижение результата

2. Свойство обучаемости

Обучаемость - это свойство качественного изменения результата работы модели за счёт изменения собственных параметров или структуры и вида изначальных данных.

Не обязательно изменять собственные веса, иногда в целом вообще может не быть модели, а только из алгоритма. Например есть расстояние между 2-мя точками в многомерном пространстве его мы не обучаем, а только измеряем, а потом по полученному значению начинает работать алгоритм.

2. Общие свойства интеллектуальных алгоритмов.

Подготовка данных для обучения моделей. Основные этапы.

Подготовка данных для обучения моделей

Основные этапы -

1. Data Collection - поиск релевантных, правдивых и структурированных данных для обучения модели, а также методы обеспечения и контроля качества.
2. Очистка данных - Выявление и исправление ошибок или несоответствий в данных, таких как пропущенные значения, выбросы, аномалии и дубликаты.
3. Интеграция данных - Объединение данных из нескольких источников для создания единого набора данных: слияния данных, сопоставление схем данных и связывание однородных записей.
4. Преобразование данных - Преобразование данных в подходящий для анализа формат: нормализация, стандартизация и дискретизация.

5. Сокращение данных - Предполагает уменьшение размера набора данных при сохранении важной информации: выбор признаков, извлечение признаков, сэмплинг, сжатие данных.
6. Аугментация данных - Создание новых данных на основе уже существующих (изменением существующих, либо изучением закономерности), в условиях малого количества данных или существовании дисбаланса классов.
7. Генерация данных - Создание абсолютно новых данных на основе некоторых правил, статистических методов и генеративных интеллектуальных моделей, если нет нужного набора данных, либо его невозможно собрать, но известен определённый закон, алгоритм или какая-либо закономерность, по которой их можно воспроизвести.

3. Общие свойства интеллектуальных алгоритмов. Подготовка данных для обучения моделей. Методики Data collection.

Методики Data collection -

Data collection - Сбор данных (Data collection) - процесс поиска релевантных, правдивых и структурированных данных для обучения модели, а также методы обеспечения и контроля качества.

Какие есть варианты поиска и методы контроля качества -

1. По классу источника:

Первичные (сам собрал)

Вторичные (собранные другими, в том числе для других целей)

- (kaggle, Hugging Face, google dataset search, amazon datasets, Azure)

2. Инструменты сбора данных:

опросы (личные, онлайн, телефонные)

ролевые игры (а если бы ты был президентом....)

наблюдения

датчики и телеметрия

3. Типичные проблемы -

противоречия в данных (датчик собрал данные, а датчик был выключен)

время простоя данных (устарели)

неоднозначность данных (ограниченная группа)

дубликаты данных

большие данные (много пропусков, шума)

неточные данные

скрытые данные

релевантные (насколько они подходят нам)

4. Обеспечение качества (quality assurance) данных представляет собой комплекс действий, выполняемый перед сбором данных и направленный на создание универсального протокола сбора данных (единая профилактика).

5. Контроль качества (quality control) представляет собой комплекс действий, направленных на наблюдение и исправление ошибок сбора данных, которые заключаются в документировании процессов сбора, мониторинге, действиях по исправлению ошибок при сборе данных и минимизации будущих ошибок.

ЗАНЯТИЕ №2

4. Дискриминативные технологии искусственного интеллекта. Принцип работы. Детерминированные и Стохастические модели. Проблемы разделения.

Дискриминативные технологии ИИ -

Принцип работы - моделирование $P(Y|X)$

Общая концепция - учатся моделировать границы принятия решений - разделяют и объединяют точки данных, не предоставляя модели того, как эти точки были созданы, но учитывая взаимозависимость признаков. (Модель не понимает откуда берётся что либо, она определяет вероятность (например пиксель травы появится рядом с собакой, не определяя где вообще пиксель может находиться)) (событие пиксель травы и пиксель собаки могут появиться вместе на определенной плоскости).

1. Обучение прямому правилу принятия решения, которое сопоставляет входные данные X с выходными данными Y .
(есть класс собака, с какой вероятностью появится класс кость)
2. Предсказание условной вероятности метки y с учетом набора характеристик x .
(есть набор категорий, по ним определить другую категорию)
3. Предсказание непрерывной величины y при наборе характеристик x .
(по числам определить другое число)

4. Определение сходства характеристик объекта x относительно объекта y .
(по общим и отдельным признакам имперически определить что куда идёт)
5. Обычно обучаются для разделения страт или для минимизации ошибки прогнозирования при выбранной функции потерь.

Детерминированные и Стохастические модели. (принцип разделения)

Детерминированные - при одинаковых входных данных детерминированная модель всегда будет выдавать одинаковый результат. (Можем со 100% уверенностью определить куда мы пойдём дальше. (из какого состояния в какое)) Если есть хоть какая-то маленькая вероятность, уже не считается детерминированным.

Принятые детерминированные алгоритмами считаются:

1. Линейная регрессия
2. Логистическая регрессия
3. Метод опорных векторов
4. Деревья решений

Стохастические - присваивают вероятности различным исходам, предоставляя распределение возможных результатов, а не одно детерминированное значение. (с вероятностью 70% вам дадут страховку)

1. Байесовские модели и сети
2. Гауссовские модели
3. Случайный лес
4. Градиентный бустинг
5. Искусственные нейронные сети
6. Скрытые марковские модели

Проблемы разделения

1. Машинное обучение по своей сути стохастично, так как обучения может включать случайную инициализацию, стохастическое обновление, случайное перетасовывание данных или стохастическую регуляризацию.
2. Не все модели, принятые относить к машинному обучению, являются интеллектуальными, что относится к многим моделям классификации и регрессии.
3. Даже результат стохастических моделей может быть предсказуемым (в том числе даже ответ языковой модели из-за генерации токенов по наиболее вероятной цепочке событий).
4. Даже детерминированная изначально модель может иметь недетерминированный результат (например, в системе продукционных правил на выходном слое может находиться генератор случайных чисел).
5. Часто стохастическими называют не вероятностные модели, а модели, которые трудно вычислимы или интерпретируемы (даже нейронную сеть можно обучать детерминированными оптимизаторами).

5. Дискриминативные технологии искусственного интеллекта. Основные разделы дискриминативного искусственного интеллекта. Предварительная обработка данных. Поиск ассоциативных правил в задачах дискриминативного и генеративного искусственного интеллекта.

Основные разделы дискриминативного искусственного интеллекта:

Предварительная обработка данных

Поиск ассоциативных правил

Кластеризация

Классификация

Регрессия

Анализ временных рядов

Предварительная обработка данных

Задача: подготовка сырых данных из различных источников путём их преобразования и объединения в единый валидный набор полезных данных

Основные алгоритмы: все методы data collection, data pre-processing и data augmentation.

Область применения -

1. Основные алгоритмы: все методы data collection, data pre-processing и data augmentation.
2. Подготовка данных для обучения интеллектуальных моделей
3. Обработка данных для хранилищ данных (в том числе для борьба с проблемой больших данных)

Пайплайн -

1. Удаление бесполезных массивов данных: дубликатов и целиком или почти целиком пустых строк.
2. Визуализация зависимостей основных признаков, всего набора данных с помощью методов понижения размерности, корреляций, баланса классов и распределения данных.
3. Поиск и обработка шумовых значений (аномалий, артефактов, выбросов)
4. Преобразование данных в числовой вид (энкодирование, нормализация, стандартизация).

Поиск ассоциативных правил

Задача: процесс выявления ассоциативных правил (связанных паттернов) на основе критерия частоты совместной встречи соответствующими методами. Понять насколько часто элемент x встречается с элементом y.

Основные алгоритмы: Apriori, Eclat, FP-growth, RElim.

Область применения:

Анализ потребительской корзины

Медицинская аналитика

Анализ технических неполадок

Поиск правил для экспертных систем

Пайплайн:

1. Определение критериев выполнения правил/завершения работы алгоритма.
2. Поиск ассоциативных правил (как правило, в ширину или глубину).
3. Расчёт метрик ассоциативных правил.

Частота встречи (Lambda): показатель количества встречи объекта или правила в наборе данных.

Мера частоты совместной встречи объектов.

$$\text{support} = P(A \rightarrow B) = P(A \cap B) = \frac{n(A \cap B)}{n(\text{total})}$$

Поддержка:

Мера, определяющая выполнение правила пары относительно одного из её элементов, если предмет встречается настолько же часто, насколько встречается в паре, то он зависим от второго объекта.

$$\text{conf}(A \rightarrow B) = \frac{\text{support}(A \cup B)}{\text{support}(A)}$$

Достоверность:

Относительная мера сравнения фактической и ожидаемой частот встречи объектов, если фактическая частота превышает ожидаемую, то объекты связаны, если частоты равны, то правило является совпадением, если фактическая частота меньше, то объекты взаимоисключающие (возможно, взаимозаменяемые).

$$\text{lift}(A \rightarrow B) = \frac{\text{support}(A \cup B)}{\text{support}(A) \times \text{support}(B)}$$

Лифт:

Абсолютная мера сравнения фактической и ожидаемой частот встречи объектов, имеет свойства, схожие с лифтом за исключением области допустимых значений (как раз из-за абсолютного характера величины).

$$\text{average}(A \rightarrow B) = \text{support}(A \cup B) - \text{support}(A) \times \text{support}(B)$$

Рычаг:

Относительная мера ожидаемой частоты возникновения Антецедент без Консеквента к наблюдаемой частоте неверных предсказаний демонстрирующая, насколько увеличилась бы вероятность ошибки, если бы связь между X и Y была чисто случайной.

$$\text{conv}(A \rightarrow B) = \frac{1 - \text{support}(B)}{1 - \text{conf}(A \rightarrow B)}$$

Уверенность (убежденность):

4. Экспертная оценка правил.

6. Дискриминативные технологии искусственного интеллекта. Основные разделы дискриминативного искусственного интеллекта. Классификация и регрессия в задачах дискриминативного и генеративного искусственного интеллекта.

Классификация и регрессия в задачах дискриминативного и генеративного искусственного интеллекта.

Классификация

Задача: предсказательная задача определения класса объекта, выполняемая с помощью обучения с учителем, где в обучающем наборе данных содержатся метки классов и свойственные им признаки

Основные алгоритмы: SVM, логистическая регрессия, k-nn, наивный Байес, дерево решений и случайный лес.

Область применения:

Фильтрация контента (письма, мультимедиа, комментарии и т.п.)

Рекомендательные системы

Анализ рисков

Анализ принадлежности к социальным группам

Анализ мошеннической деятельности

Медицинская диагностика.

Регрессия

Задача: Поиск функциональной зависимости между зависимой/зависимыми (предсказываемыми) и независимыми переменными (известными)

Основные алгоритмы: линейная, полиномиальная, лассо-, гребневая и робустая регрессии, Elastic Net, k-nn, дерево решений.

Область применения:

1. Прогнозирования валидных показателей: прогнозирование цен, выплат и других экономических показателей в зависимости от параметров объектов (например, возраст, размер, цвет и т.п., а не от времени, как это делается в анализе временных рядов).
2. Прогнозирование тенденций: прогнозирование затрат и получений ресурсов на основе исторических данных
3. Выявление и анализ рыночных рисков: поиск зависимости риска потерь и убытков от различных факторов
4. Выявление факторов медицинских рисков: анализ и прогнозирование изменения числовых медицинских показателей

Пайплайн:

1. Определение шумовых значений целевой переменной и аугментация данных (при необходимости).
2. Разбиение данных на обучающую, валидационную и тестовую выборки.
3. Выбор и обучение моделей регрессии в зависимости от распределения (особенно кривизны для выбора

линейных и нелинейных моделей), количества данных и шумов для выбора линейных и нелинейных моделей (в том числе ансамблей в случае проблемы с любым из выше перечисленных пунктов).

4. Расчёт метрик качества регрессии для определения степени аппроксимации исходной зависимости переменных.
5. Предсказание (интерполяция и экстраполяция) значения функции для новых точек данных.



Интерполяция – метод поиска промежуточных значений величины на основе дискретного набора известных данных.



Экстраполяция – это метод научного прогнозирования и анализа, заключающийся в распространении тенденций, установленных для одной части данных (прошлого или настоящего), на область, находящуюся за пределами известных значений (будущее или прошлых неохваченные явления).

7. **Дискриминативные технологии искусственного интеллекта. Основные разделы дискриминативного искусственного интеллекта. Кластеризация как основа генеративного искусственного интеллекта.**

Кластеризация

Задача: объединения данных на основе общих признаков

Основные алгоритмы: k-means, DBSCAN, AGNES, STING, GMM.

Область применения:

Сегментация клиентов и рынков

Анализ потребительской корзины

Анализ социальных сетей и связей

Поиск закономерностей и групп риска при медицинских исследованиях

Инженерия данных (предобработка - обработка аномалий, шумов, группировка данных)

Основа для классификации (требует осмысление кластеров)

Пайплайн:

1. Определение соседства точек на основе критерия сходства (как правило, метрики математического расстояния).
2. Создание границы кластера на основе плотности, центров и шумовых точек путём добавление новых точек в кластеры.
3. Расчёт метрик качества кластеризации, оценивающих распределение признаков.
4. Выбор итоговых алгоритмов кластеризации на основе распределения данных (особенно по результатам визуализации) и метрик качества.
5. Кластерный анализ (анализ общих и наиболее распространённых признаков кластеров для определения "истинного" сходства объектов, а также отличия от других кластеров) с целью создания стратегии работы с объектами внутри кластеров.

ЗАНЯТИЕ №3

8. Генеративные технологии искусственного интеллекта. Генерация табличных данных. Принцип работы. Описание основных разделов.

Принцип работы - моделирование $P(X, Y)$

**Общая концепция: позволяет найти модель генерации точек
- определяет способ создания набора данных, пытаясь
понять распределение точек данных.**

Описание основных разделов:


1. Продукционные правила
в которые входят децентрализованная генерация табличных значений и Преобразование "продукция-онтология" для создания централизованной модели представления знаний (МПЗ)
2. Машинное обучение
в которое входит первое поколение (модели гауссовых смесей, Copula, и Bayesian Networks) и актуальные (т.е Байесовская модель GMM (BGM), SMOTE и его модификации (Synthetic Minority Over-sampling Technique), а также Random Forest Distribution)
3. нейронные сети
также есть первое поколение (CNN и RNN для таблиц) и актуальные, а именно (GAN, TVAE, TabDDPM)
4. Эволюционные алгоритмы

основанные на генетических алгоритмах и локальные разновидности.


**9. Генеративные технологии искусственного интеллекта.
Генерация табличных данных. Продукционные правила.
Децентрализованная генерация. Построение онтологий
знаний.**

Децентрализованная генерация табличных значений:



Работает по принципу - на основе условий правил уточняются значения определённых параметров, в результате чего создаётся новое значение, например: IF character_lvl > 10 AND character_class == "warrior" THEN spawn(skeletons, min=5, max = 10, swapon = "bow").




**Преобразование "продукция-онтология" для создания
централизованной модели представления знаний (МПЗ):**



Представление знаний - проблема на стыке когнитологии, информатики и искусственного интеллекта, решением которой являются модели, позволяющие описывать базу знаний предметной области как совокупность данных о предметной области и правил взаимодействия с ними.



Преобразования Базы данных и Базы правил определённой предметной области в Базу знаний с последующим её отображением в виде Семантической сети.



Семантическая сеть:


информационная модель предметной области, имеющая вид помеченного (вершины и дуги графа имеют определённые метки) ориентированного графа, вершины которого соответствуют объектам предметной области, а дуги (рёбра) задают отношения между ними.

$S = \langle V, A, L \rangle$, где

V – вершины графа, являющиеся определёнными понятиями ПрО


A – дуги графа, являющиеся отношениями между понятиями ПрО

L – метки вершин и дуг графа.



10. Генеративные технологии искусственного интеллекта.
Генерация табличных данных. Машинное обучение. Первое поколение. Модели гауссовых смесей. Байесовские сети.


Модели гауссовых смесей



вероятностная модель, предполагающая, что точки данных генерируются из смеси нескольких гауссовых (нормальных) распределений признаков с неизвестными параметрами.

Обучается на реальных данных, используя алгоритм Expectation-Maximization (EM), чтобы найти оптимальные параметры: средние значения (mean), ковариационные матрицы (covariance) для каждого кластера и веса (вероятности) этих компонентов.

Области применения: для оценки плотности, мягкой кластеризации и генерации синтетических данных путем выборки из обученных кластеров.



итеративный метод поиска оценок максимального правдоподобия параметров вероятностных моделей, содержащих скрытые (ненаблюдаемые) переменные, чередует Е-шаг (оценка скрытых переменных) и М-шаг (оптимизация параметров) до сходимости, что позволяет находить оптимальные кластеры или параметры распределений]

Е-шаг (Expectation, ожидание): на основе текущих параметров вычисляются вероятности того, что данные принадлежат к определенным скрытым состояниям или кластерам.



М-шаг (Maximization, максимизация): параметры модели пересчитываются (максимизируются) так, чтобы максимально правдоподобно объяснить данные, полученные с учетом весов из Е-шага.

$$p(\mathbf{x}) = \sum_{i=1}^K \pi_i \cdot \mathcal{N}(\mathbf{x} | \mu_i, \Sigma_i)$$

- $p(\mathbf{x})$ — плотность вероятности того, что модель сгенерирует точку $\mathbf{x}$.
- K — количество гауссовских компонентов в смеси (гиперпараметр, который нужно задать заранее).
- π_i — вес i -го компонента, показывающий, какую долю данных он генерирует. Выполняется условие: $\sum_{i=1}^K \pi_i = 1$, и $\pi_i \geq 0$.
- $\mathcal{N}(\mathbf{x} | \mu_i, \Sigma_i)$ — функция плотности вероятности i -го многомерного нормального распределения.
- μ_i — вектор средних значений i -го компонента (центр кластера в многомерном пространстве).
- Σ_i — ковариационная матрица i -го компонента (задает форму и ориентацию кластера).
- $\mathbf{x}$ — вектор признаков одной строки данных, который мы моделируем.

$$\mathcal{N}(\mathbf{x} | \mu_i, \Sigma_i) = \frac{\exp\left(-\frac{1}{2}(\mathbf{x} - \mu_i)^T \Sigma_i^{-1}(\mathbf{x} - \mu_i)\right)}{(2\pi)^{p/2} |\Sigma_i|^{1/2}}$$

Функция плотности многомерного нормального распределения:




11. Генеративные технологии искусственного интеллекта. Генерация табличных данных. Машинное обучение. Первое поколение. Модель Copula. Актуальные модели. Метод SMOTE.


Copula

отделяет описание зависимости между переменными от описания их индивидуальных (маргинальных) распределений, что позволяет моделировать взаимосвязи в данных, не делая предположений о форме самих распределений признаков, сама функция вида Copula описывает, как связаны между собой

переменные, в то время как "поля" задают распределение каждой переменной по отдельности.



Функция вида Copula:



многомерная функция распределения, определенная на единичном гиперкубе $[0, 1]^n$, маргинальные (маржинальные) распределения которой равномерны на интервале $[0, 1]$, позволяет описывать совместное распределение нескольких случайных величин, разделяя структуру зависимости между

ними и маргинальные (частные) распределения каждой величины.

вероятностные распределения подмножества случайных величин, входящих в состав многомерного (совместного) распределения. Они позволяют определить вероятность значений отдельных переменных, игнорируя остальные, путем суммирования (для дискретных) или интегрирования (для непрерывных) совместной плотности.

Показывает связи между переменными, а поля метода задают распределение.

Метод SMOTE -

$$\mathbf{x}_{\text{new}} = \mathbf{x}_i + \lambda \cdot (\mathbf{x}_{nn} - \mathbf{x}_i)$$

SMOTE и его модификации (Synthetic Minority Over-sampling Technique)

Вместо простого копирования примеров из меньшинства, создает новые синтетические примеры, интерполируя между существующими точками (генеративный алгоритм только в широком смысле).

- $\mathbf{x}_{\text{new}}$ — созданный синтетический вектор признаков.
- $\mathbf{x}_i$ — исходный вектор признаков из меньшинства.
- $\mathbf{x}_{nn}$ — один из k ближайших соседей $\mathbf{x}_i$.
- λ — случайное число в интервале $[0, 1]$, которое контролирует, насколько новая точка близка к исходной ($\lambda = 0$) или к соседу ($\lambda = 1$).

Где:

В чем идея -


В многомерном пространстве берем 2 точки (как в лекции, назовём мама и папа), считаем евклида между ними, берем лямбду этого расстояния от 0 до 1, и умножаем расстояние между ними на лямбду, Если расстояние ближе к 0, значит это Мама, если ближе к 1-це, значит папа

12. Генеративные технологии искусственного интеллекта.


Генерация табличных данных. Искусственные нейронные сети.

Первое поколение. Применение CNN и RNN в генеративных задачах.

CNN:




работы начала 2010-х годов преобразовывали табличные данные в изображения (например, через преобразование Грама) или использовали одномерные свёртки вдоль строк.



Математический алгоритм, который преобразует набор линейно независимых векторов в ортогональный (или ортонормированный) базис, сохраняя исходное линейное пространство. Он поочередно корректирует каждый вектор, делая его перпендикулярным предыдущим

RNN



LSTM-сети использовались для моделирования строк как последовательностей, особенно в медицинских и финансовых данных, где столбцы имели естественный порядок (например, временные срезы).

ЗАНЯТИЕ №4

13. Генеративные технологии искусственного интеллекта. Генерация табличных данных. Искусственные нейронные сети. Актуальные модели. TGAN. CTGAN. Отличие от стандартного GAN – адаптация под табличные данные. Генератор. Дискриминатор. Классификатор.

14. Генеративные технологии искусственного интеллекта. Генерация табличных данных. Искусственные нейронные сети. Актуальные модели. TVAE. Отличие от стандартного VAE – адаптация под табличные данные. Энкодер. Декодер. Латентное пространство.

15. Генеративные технологии искусственного интеллекта. Генерация табличных данных. Искусственные нейронные сети. Актуальные модели. TabDDPM. Отличие от стандартной DPM – адаптация под табличные данные. Прямой и обратный процесс диффузии. Непрерывная релаксация и Квантильный трансформер.

16. Генеративные технологии искусственного интеллекта. Генерация табличных данных. Метрики качества. Объективные метрики. TSTR. Методика разрешённых и запрещённых условий.

Метрики качества - Существует 2 типа, объективные и субъективные.

Главная объективная метрика - TSTR (train in synthetic, Test on Real) - обучаем на синтетических данных (сгенерированных) и сравниваем с результатом такой же модели, обученной на реальном датасете и смотрим как они отвечают при равных условиях.

Разрешенные и запрещенные условия -

Когда мы явно говорим что что-то должно или не должно быть. Например данные не могут быть правильные если у 2-х летней девочки в данные есть дети.

**17. Генеративные технологии искусственного интеллекта.
Генерация табличных данных. Метрики качества.
Субъективные метрики. SHAP. SDR. Статистические меры.**

Субъективные метрики

SHAP - (Shapley Additive exPlanations)

проверяет одинаково ли модель рассуждает при работе при работе с реальными и синтетическими данными. Например если при работе с реальными и синтетическими данными одна и та же модель придала важность разными признакам (пол и зарплата при выдаче кредита) то модель не так угадала идею, следовательно неправильно обучили.

18. Генеративные технологии искусственного интеллекта. Генерация табличных данных. Аугментация табличных данных (причины, особенности и проблемы). Модельная, нейронная и статистическая аугментация табличных данных.

19. Генеративные технологии искусственного интеллекта. Генерация мультимедийных данных. Описание основных разделов. Особенности разных мультимедийных модальностей (изображений, видео и звука).

Общая концепция: попытка создать видоизменённое исходное изображение из обучающего набора данных, для чего либо производится зашумление исходных данных, либо создание подражающего изображения из первородного шума.

То сначала мы исходное изображение зашумляем в труху, потом создаём новое, похожее на первородное.

Особенности разных мультимедийных модальностей (изображений, видео и звука).

ответ на этот вопрос будет далее где есть GAN, VAE AE итд.


20. Генеративные технологии искусственного интеллекта. Генерация мультимедийных данных. Архитектура GAN. Генератор. Дискриминатор. Пайплайн обучения. Проблема коллапса режимов.

GAN - Generative Adversarial Network) -

Генератор. Дискриминатор

Генератор (подделыватель) создает изображения из случайного шума, стремясь обмануть Дискриминатора. Дискриминатор (детектив) одновременно учится отличать реальные изображения из датасета от подделок. Это соревнование заставляет Генератор создавать все более реалистичные изображения.

Пайплайн -



Хотя GAN способны генерировать очень четкие изображения, они известны своей нестабильностью обучения и явлением "коллапса режимов", когда Генератор начинает создавать очень похожие или одинаковые изображения


проблема в том что есть коллапс режимов (либо генератор гением стал, либо дискриминатор) либо вообще дискриминатор перестанет всё пропускать или начнёт пропускать всё и убьёт просто дискриминатор.

21. Генеративные технологии искусственного интеллекта. Генерация мультимедийных данных. VAE. Отличие VAE от стандартного АЕ. Энкодер. Декодер. Латентное пространство. Функция ошибок VAE.

VAE (variational Autoencoders) -

VAE состоит из двух частей: Кодировщика и Декодировщика. Кодировщик(Encoder) сжимает входное изображение не в одну точку, а в целую область в "скрытом пространстве" (в виде набора вероятностей). Затем из этой области случайно выбирается точка, и Декодировщик(Decoder) восстанавливает из нее изображение. Это позволяет VAE не просто копировать, а генерировать новые, похожие изображения

Кодировщик получает на вход реальное изображение и предсказывает параметры распределения скрытого слоя z . Из этого распределения извлекается конкретный вектор z , который подаётся на вход декодеру для восстановления исходного изображения. Новая картинка создаётся путём подачи случайного вектора z на вход декодера.



Пример из лекции -

у кодировщика есть своё виденье своего сайта из разряда о, хочу вот так, потом он собрал это всё (например вот тут эта кнопка, тут вот так итд) и ближе к центру, все цвета, положения превращаются в информацию(инструкцию) как это

воспроизвести(куда пройти, какой угол, какой цвет итд), а декодер это всё достаёт. расшифровывает и делает

Латентное пространство VAE - вариационный байесовский вывод (variational Bayesian inference), позволяет модели не хранить конкретный образ объекта, а формирует множество возможных состояний, в которых этот объект может существовать.

мы храним только сеть и начальное состояние, не храним углы вектора. Пиксель красный - если да, то идём влево на 5 пикселей. По набору событий определяем куда и что идём рисовать.

- μ (мю) — среднее значение;
- σ^2 (сигма квадрат) — дисперсия.

Каждому примеру данных соответствует не единственный код z , а распределение с параметрами:

данные кодируются до мю и сигма, а потом сэмплируется латентный вектор z .

Функция потерь у VAE -

$$\mathcal{L}_{\text{VAE}}(\theta, \phi; \mathbf{x}) = \underbrace{-\mathbb{E}_{\mathbf{z} \sim q_{\phi}(\mathbf{z}|\mathbf{x})} [\log p_{\theta}(\mathbf{x}|\mathbf{z})]}_{\text{Потеря реконструкции}} + \underbrace{KL(q_{\phi}(\mathbf{z}|\mathbf{x}) \| p(\mathbf{z}))}_{\text{Регуляризация KL-дивергенцией}}$$

- x — исходное изображение.
- z — скрытое (латентное) представление.
- $p_{\theta}(x|z)$ — Декодировщик, который восстанавливает изображение из скрытого кода.
- $q_{\phi}(z|x)$ — Кодировщик, который преобразует изображение в скрытое представление.
- $p(z)$ — априорное распределение скрытого пространства (обычно стандартное нормальное).
- KL — дивергенция Кульбака-Лейблера, которая "заставляет" распределение q_{ϕ} быть похожим на $p(z)$, тем самым организуя скрытое пространство.

Где:

несимметричная мера различия между двумя распределениями вероятностей P и Q . показывает, сколько «лишней» информации потребуется для кодирования данных, если распределение Q используется для аппроксимации истинного распределения.

$$D_{KL}(P||Q) = \sum_i P(i) \ln \frac{P(i)}{Q(i)}$$

Дивергенция Кульбака-Лейблера (KL-дивергенция, относительная энтропия):

22. Генеративные технологии искусственного интеллекта.

Генерация мультимедийных данных. DPM. Пайплайн обучения. Прямой и обратный процессы диффузии.

DPM - Diffusion process model - Постепенного проявления постепенно на исходное изображение накладывается шум, напустили раз шум, потом попытались предсказать что изменилось, (какая функция шума была накинута и пытается подобрать обратную функцию). преимущество в том что данные невозможно восстановить доподлинно точно, но можно сделать похожее изображение с доп деталями и получается естественно (все нейрослоп пухососы это GAN и DPM)

Алгоритм -

сначала из реального изображения делают шумное изображение, затем модель учится предсказывать добавленный на каждом шаге шум. Генерация новой картинки начинается со случайного шума и модель итеративно очищает его (формируя

схожее, но не идеальное изображение) шаг за шагом убирая предсказанный шум.

Прямой процесс -

Модель учится постепенно добавлять случайный шум к изображению, пока оно не превратится в "полный" хаос.

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon$$

Прямой процесс (зашумление):

- x_0 — исходное чистое изображение.
- x_t — зашумлённое изображение на шаге t .
- ϵ — случайный гауссовский шум.
- $\bar{\alpha}_t$ — кумулятивный коэффициент зашумления, определяющий, сколько исходного сигнала осталось.

Обратный процесс -

Надтренированная нейронная сеть затем учится делать обратное: шаг за шагом убирать шум из случайного "белого шума", постепенно "проявляя" новое, реалистичное изображение.

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

- $q(x_t|x_{t-1})$ — распределение вероятностей на шаге t при заданном предыдущем состоянии x_{t-1} . Это прямое, не обучаемое преобразование, определенное заранее.
- $p_\theta(x_{t-1}|x_t)$ — распределение вероятностей на шаге $t-1$ при заданном состоянии x_t . Это **обратный процесс**, который обучает нейронная сеть, параметризованная θ .
- β_t — гиперпараметр, определяющий уровень шума на каждом шаге t .
- $\mu_\theta(x_t, t)$ и $\Sigma_\theta(x_t, t)$ — среднее и дисперсия, предсказываемые нейронной сетью для наилучшего восстановления данных из зашумленного состояния.
- I — единичная матрица, шум изотропный.

23. Генеративные технологии искусственного интеллекта. Генерация мультимедийных данных. Модели авторегрессии. Авторегрессионные свойства данных. Модели на основе пикселей и модели на основе токенов. Процесс обучения модели.

Модели авторегрессии

Модели генерируют изображение последовательно, один пиксель за другим. Каждый новый пиксель предсказывается на основе всех ранее сгенерированных, что позволяет модели идеально "запоминать" структуру изображения. Генерация одного изображения происходит очень медленно последовательно.

В основе метода лежит теорема Байеса, или правило цепочки вероятностей. Чтобы вычислить общую вероятность $p(x)$ появления целого объекта x , она "раскладывается" на произведение условных вероятностей каждого элемента объекта - x_t , который зависит от всех предыдущих $x_1, x_2, \dots, x_{t-1}$:

должны обладать авторегрессионными свойствами.

$$p(x) = \prod_{t=1}^T p(x_t | x_1, x_2, \dots, x_{t-1})$$

Процесс обучения модели заключается в том, чтобы как можно лучше выучить условные вероятности.

Пиксельные модели PixelCNN и PixelRNN - представляют изображение как длинную последовательность пикселей, обычно выстроенных в порядке слева направо и сверху вниз.

Модели на основе токенов VQ-VAE, VQ-GAN, VAR: современные модели работают не с пикселями напрямую, а с "токенами", сначала изображение сжимается в компактное скрытое представление (latent space), а затем это представление генерируется авторегрессионно.

Модели:

в основе лежат либо CNN либо RNN (выстроены либо слева-направо, либо сверху вниз)

(0x0 - левый верхний угол, строим вниз и вправо)

Модели на основе токенов - термин - храним не пиксель, а информацию о группе пикселей, это как генерировать карту в майнкрафте не по блокам, а по чанкам)

24. Генеративные технологии искусственного интеллекта. Генерация мультимедийных данных. Метрики моделей генерации мультимедиа. Дискриминативные модели для TSTR. Субъективные метрики. FID, IS, PSNR.

Метрики -

$$FID = \|\mu_r - \mu_g\|^2 + \text{Tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{\frac{1}{2}}),$$

где Tr — след матрицы, то есть сумма её диагональных элементов.

FID (Fréchet Inception Distance)

Идея - Предполагаем, что признаки изображений, как реальных, так и сгенерированных, имеют многомерное нормальное распределение. Для каждого набора изображений (реальных и сгенерированных) вычисляются:

- средний вектор признаков μ_r и μ_g для реальных и сгенерированных изображений соответственно
- ковариационная матрица Σ_r и Σ_g для реальных и сгенерированных изображений соответственно.

Низкий FID означает, что сгенерированные изображения похожи на реальные как по визуальной оценке качества, так и по разнообразию. Чем меньше значение FID, тем лучше.

Высокий FID указывает на большое расхождение между сгенерированными и реальными изображениями, что может говорить о низком качестве генерации или недостаточном разнообразии.

$$IS(G) = \exp \left(\mathbb{E}_{\mathbf{x} \sim p_g} D_{KL}(p(y|\mathbf{x}) \parallel p(y)) \right),$$

IS (Inception Score)

Оценка рассчитывается на основе выходных данных отдельной, предварительно обученной модели классификации изображений Inception v3

Энтропия распределения меток, предсказанных моделью Inceptionv3 для сгенерированных изображений, минимизируется. Другими словами, модель классификации уверенно предсказывает одну метку для каждого изображения. Интуитивно это соответствует желаемому результату: сгенерированные изображения должны быть «четкими» или «разборчивыми».

Предсказания модели классификации равномерно распределены по всем возможным меткам. Это соответствует желаемому результату, когда выходные данные генеративной модели «разнообразны».


$$\begin{aligned} PSNR &= 10 \cdot \log_{10} \left(\frac{MAX_I^2}{MSE} \right) \\ &= 20 \cdot \log_{10} \left(\frac{MAX_I}{\sqrt{MSE}} \right) \\ &= 20 \cdot \log_{10}(MAX_I) - 10 \cdot \log_{10}(MSE) \end{aligned}$$

PSNR (Peak Signal-to-Noise Ratio)

Пиксельное различие между эталонным и сгенерированным изображением. (насколько пиксель в пиксель, токен в токен)

**25. Генеративные технологии искусственного интеллекта.
Генерация мультимедийных данных. Специфические
модели генерации звука. HiFi-GAN. Вокодеры.
Мэл-спектрограмма.**


Общая концепция: звук - по своей природе одномерный сигнал с очень высокой частотой дискретизации (обычно 16 000 - 48 000 тактов в секунду), имеющий чёткую последовательность, которую с одной стороны нужно предсказать, но с другой стороны нельзя предсказывать на основе исходного спектрального ряда, так как может сгенерироваться похожий спектр.



Модель-вокодер, предназначенная для синтеза речи (text-to-speech) и генерации аудио с высокой точностью, способная генерировать звук параллельно из спектрограммы.

$$\mathcal{L}_{Adv}(D; G) = \mathbb{E}_{(x,s)} [(D(x) - 1)^2 + (D(G(s)))^2]$$

Формальное определение - состязательная потеря (Least Squares GAN):




Обсучение - Используются спектральные аугментации (например, SpecAugment), которые случайным образом маскируют части спектрограммы по времени и частоте. Сам процесс обучения может использовать функцию потерь, сравнивающую спектрограммы сгенерированного и реального звука (Mel-Spectrogram Loss).

Когда маска закрывает часть данных, чтобы модель видела только часть контекста, ибо если она будет видеть всё, она не

будет генерировать ничего нового, а будет опираться только на старое

Мэл спектрограмма - визуальное представление звука, которое отображает изменение спектра частот во времени, где частоты преобразованы в мэл-шкалу.

26. Генеративные технологии искусственного интеллекта. Генерация мультимедийных данных. Специфические модели генерации звука. WaveNet. Факторизация распределения. Метрики качества генерации звука. MCD. PESQ.



Генерируют звук последовательно, семпл за семплом, в основе WaveNet лежат причинные свёртки, которые гарантируют, что модель при предсказании не "заглядывает" в будущее.

Факторизация распределения: WaveNet моделирует совместную вероятность всей звуковой волны как произведение условных вероятностей каждого следующего семпла:

$$p(x) = \prod_{t=1}^T p(x_t | x_1, x_2, \dots, x_{t-1})$$

Формальное определение:

x – вся звуковая волна.

x_t – значение амплитуды в момент времени t .

T – общее количество временных отсчётов.

Метрики -


$$MCD = \frac{10}{\ln 10} \frac{1}{T} \sum_{t=1}^T \sqrt{2 \sum_{i=1}^M (mc_{syn}(t, i) - mc_{ref}(t, i))^2}$$

MCD (Mel Cepstral Distortion):

Разница между спектральными характеристиками речи.

- T : Общее количество кадров (фреймов) в речевом сигнале.
- M : Количество мел-кепстральных коэффициентов (обычно 25-D или 13-D без учета нулевого коэффициента).
- $mc_{t,i}$: i -й мел-кепстральный коэффициент синтезированного сигнала на кадре t .
- $mc_{t,i}^{ref}$: i -й мел-кепстральный коэффициент эталонного (натурального) сигнала на кадре t .
- $\frac{10}{\ln 10}$: Коэффициент для перевода величины в децибелы (dB).
- $\sqrt{2 \sum \dots}$: Евклидово расстояние между векторами MFCC на каждом кадре.

Где:



оцениваем что вообще происходит на аудио




насколько она научилась воспроизводить - сколько языков, говорящих.

27. Генеративные технологии искусственного интеллекта. Генерация мультимедийных данных. Специфические модели генерации видео. Векторно-квантованные автоэнкодеры. Отличия процесса обучения от классических VAE.


Общая концепция: наиболее сложный тип данных, так как сочетает одновременно пространственные и временные характеристики.

Векторно-квантованные автоэнкодеры (VQ-VAE):



Сжимают видео в дискретные "токены", похожие на слова в языке.

Создать видео можно двумя способами: итеративно очищая случайный пространственно-временной шум или создавая кадры последовательно, используя предыдущие сгенерированные кадры как условие для создания следующих.




Обучение:

Принцип тот же, что и для изображений, но шум добавляется и убирается сразу на всей пространственно-временной структуре.

Применяются пространственные аугментации (кадрирование) и временные аугментации (изменение частоты кадров, воспроизведение в обратном порядке).

28. Генеративные технологии искусственного интеллекта. Генерация мультимедийных данных. Специфические модели генерации видео. Общая концепция. Метрики оценки качества видео. FVD.

Метрики -




Схожесть распределения сгенерированных и реальных видео в пространственно-временном континууме.

$$\text{FVD}(r, g) = \|\mu_r - \mu_g\|_2^2 + \text{Tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2})$$

Формальное определение (аналогично FID):

KVD



Сходство распределений видео с использованием ядерных методов.

- $\phi(x)$: Отображение точки x в признаковое пространство.
- $k(x, y)$: Ядерная функция (например, RBF/Гауссово ядро: $k(x, y) = \exp(-\frac{\|x-y\|_2^2}{2\sigma^2})$).
- $k(x, x)$ и $k(y, y)$: Значения ядра для точек с самими собой (обычно равны 1, если ядро нормировано).

Где:

$$\|\phi(x) - \phi(y)\|_2^2 = k(x, x) + k(y, y) - 2k(x, y)$$

Формальное определение:

ЗАНЯТИЕ №5

29. Генеративные технологии искусственного интеллекта.

Обработка естественного языка (задача NLP). Описание основных разделов. Виды языковых моделей. Задачи, решаемые разными видами языковых моделей.

а. NLP (Natural Language Processing) — это область искусственного интеллекта, которая учит компьютеры

понимать, интерпретировать и генерировать человеческий язык. Главные задачи NLP включают классификацию текстов, извлечение информации, машинный перевод, суммаризацию, анализ тональности, а также распознавание и синтез речи.

- b. Содержат миллионы параметров и является специфическими для каждой отдельной взятой задачи, основные недостатки связаны с последовательной обработкой данных и статичными эмбедингами (один и тот же вектор на слово при разных контекстах), однако куда меньше, чем большие языковые модели, учатся и работают быстрее, могут работать в условиях малых текстов и задач и тем самым выступать в качестве бейзлайн-модели (baseline))

30. Генеративные технологии искусственного интеллекта. Обработка естественного языка (задача NLP). Языковые модели первого поколения. Токенизаторы. One-hot encoding. BPE. WordPiece. Типичные задачи.

- a. **Токенизаторы** - Создают проблему "проклятия размерности" и не улавливают семантической близости слов – проклятие размерности: с увеличением количества признаков (размерностей) объем пространства данных растет экспоненциально, чем больше признаков, тем больше «пустоты» между объектами – семантическая близость слов: показатель того, насколько близки два слова или фразы по смыслу, а не по написанию или не только по написанию.
- b. **Выполняемые задачи:**
 - i. **Сегментация текста и токенизация. P.S.:**
для языков без пробелов (японский,

китайский) до сих пор используют словарные методы (максимальное сопоставление).

ii. **Поиск по ключевым словам и regex** - извлечение email, дат, телефонов из текстов.

iii. **Орфографическая коррекция** – n-граммные модели на основе токенов могут быстро предлагать исправления опечаток.

iv. **Классификация текстов** (спам-фильтры, распределение обращений в поддержку), например, Bag-of-Words или TF-IDF с SVM быстро работают и легко интерпретируются

v. **Анализ тональности коротких отзывов**: простая модель на униграммах (одно слово) может дать достаточную точность на маленьком датасете.

с. Примеры инструментов:

i. **One-hot encoding** - Каждое слово представляется как вектор из нулей и одной единицы. Размерность вектора равна размеру словаря.

ii. **Byte-pair encoding** - Итеративно объединяет самые частые пары токенов в новые токены. Это позволяет разбивать редкие слова на известные подслова.

iii. **WordPiece** - Схож с BPE, но выбирает пары для объединения на основе наибольшего увеличения правдоподобия обучающих данных: проверяет различные

комбинации символов (или подслов) и объединяет ту пару, которая дает наибольший прирост качества (вероятности) языковой модели на обучающем корпусе. При обработке нового текста алгоритм ищет самое длинное подслово, которое есть в его словаре, а остальную часть слова продолжает делить дальше.

31. Генеративные технологии искусственного интеллекта. Обработка естественного языка (задача NLP). Малые (классические) языковые модели. Word2Vec. Seq2Seq. Типичные задачи.

Классические языковые модели - Основаны на концепции дистрибутивной семантики: "слово характеризуется его окружением".

i. Выполняемые задачи:

- 1. Задачи последовательной разметки** (POS-теггинг, NER): однослойный LSTM с CRF на выходе может быть в сотни раз компактнее и быстрее трансформера, работая на CPU в реальном времени.
- 2. Обработка сигналов в реальном времени:** распознавание речи на устройстве - RNN обрабатывает семпл за семплом, не требуя полного контекста.
- 3. Языковое моделирование на малых масштабах:** для генерации текстов в системах с очень

ограниченной памятью (микроконтроллеры) используют легковесные LSTM-модели.

4. **Обучение на сверхмалых данных:** когда выборка состоит из сотен примеров, простая рекуррентная сеть может обобщить лучше, чем склонный к переобучению трансформер.

ii. **Word2Vec** - Использует двухслойную нейронную сеть для получения плотных векторов слов. Алгоритм "Skip-gram с Negative Sampling": модель выбирает центральное слово, например, и учится предсказывать слова его контекста. *То есть, здесь один бинарный вектор должен предсказывать другой бинарный вектор.*

1. **Формальное определение** -


$$J = \sum_{i,j=1}^V f(X_{ij})(w_i^T \tilde{w}_j + b_i + \tilde{b}_j - \log X_{ij})^2$$

2. X_{ij} - частота, с которой слово j встречается в контексте слова i .
3. w_i и $\tilde{w}_j$ - векторы слов.
4. Функция $f(X_{ij})$ - ограничивает влияние слишком частых пар слов (например, предлогов).
5. GloVe стремится, чтобы скалярное произведение векторов слов приближало логарифм их совместной встречаемости.

iii. **Рекуррентные нейронные сети (RNN)** - Обработывают последовательности, где

порядок слов имеет значение (RNN, LSTM, Seq2Seq).

1. **Seq2Seq (Sequence-to-Sequence) с механизмом Внимания** - модель состоит из энкодера, сжимающего входную последовательность в вектор контекста, и декодера, который из этого вектора генерирует выходную. Проблема в том, что один вектор контекста - "бутылочное горлышко" для длинных текстов.



2. **Механизм Внимания (Bahdanau Attention):** позволяет декодеру на каждом шаге генерации "смотреть" на все скрытые состояния кодера, а не только на последнее, решая проблему "забвения".

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

Bahdanau Attention:

Q (Query) — запрос (текущее состояние декодера).

K(Keys) и V(Values) - ключи и значения (состояния кодера). Вычисляются "веса внимания" через softmax, которые показывают, на какие части входного предложения нужно обратить внимание при генерации следующего слова.

d_k - размерность ключей, используется для масштабирования.

32. Генеративные технологии искусственного интеллекта. Обработка естественного языка (задача NLP). Большие языковые модели. Трансформер. Обзор видов трансформеров. Специфические задачи трансформеров.

- a. **Трансформеры** относятся к большим языковым моделям (LLM) – та же самая концепция Внимания (многих видов) – тот же Seq-to-seq, только в абсолют возведен механизм Внимания.
- b. Каждый слой трансформера состоит из двух основных подслоёв с остаточными связями (residual connections): **механизма внимания и полносвязной сети (Feed-Forward Network, FFN).**



i.

- ii. **Полносвязный слой** - Каждый нейрон текущего слоя математически связан с каждым нейроном предыдущего слоя,

объединяет извлеченные признаки для принятия итогового решения.

iii. **Резидуальный слой** - Отличается наличием «пропускной связи» (skip connection). Она передает входные данные слоя напрямую дальше, позволяя сети избегать проблем с затуханием градиента при обучении.

$$\text{FFN}(x) = W_2 \cdot \text{GELU}(W_1 \cdot x + b_1) + b_2$$

- x : Входной вектор (например, `hidden_size = 768` для BERT Base).
- W_1, W_2 : Обучаемые весовые матрицы. Первая расширяет размерность вектора в 4 раза (для BERT Base W_1 имеет размер 768×3072), а вторая сжимает её обратно (3072×768).
- b_1, b_2 : Соответствующие векторы смещений (bias).
- **GELU** : Функция активации. Это гладкая аппроксимация ReLU (Gaussian Error Linear Unit). В отличие от ReLU, которая просто "обнуляет" отрицательные значения, GELU взвешивает входные данные по их величине, что делает обучение более стабильным и позволяет модели улавливать более сложные закономерности.

iv. **Внимание** - математический механизм, который позволяет модели динамически определять, какие слова (или части данных) во входном тексте наиболее важны друг для друга, заставляет фокусироваться на нужном контексте. **Состоит из 3 компонентов** - **Запрос** (Query, Q): То, что слово «спрашивает» или ищет в остальном тексте; **Ключ** (Key, K): «Тэг» или категория слова; **Значение** (Value, V): Изначальный смысл или информация, которую слово передает дальше, если запрос подошел.

1. **Модель умножает вектор Запроса одного слова на вектор Ключа всех остальных слов.** Чем больше получившееся число, тем сильнее связь

(больше вес внимания). Затем эти веса умножаются на Вектор Значений и суммируются - так формируется итоговый результат.

2. Многоголовое внимание (Multi-Head Attention) -

позволяет нейросети разбивать задачу обработки текста на несколько независимых потоков, благодаря этому модель может одновременно фокусироваться на разных типах связей в предложении (например, грамматике, смысле или интонации) для более точного понимания контекста.

3. Маскированное внимание - алгоритмический

фильтр в нейросетях трансформерах, который принудительно запрещает модели смотреть в будущее: перед вычислением важности слов алгоритм накладывает математическую «маску» (обнуляет веса) для всех позиций, находящихся справа от текущего слова.


с. Главное преимущество - параллельная обработка всей последовательности слов. Трансформер состоит из кодера и декодера, но используется по-разному в зависимости от задачи: только кодер (BERT), только декодер (GPT) или и то, и другое (T5).

33. Генеративные технологии искусственного интеллекта. Обработка естественного языка (задача NLP). Компоненты архитектуры трансформера. Механизм внимания и виды внимания. Дообучение языковых моделей. Fine-Tuning. PEFT. Retraining.

a. Дообучение (Fine-Tuning)

- i. **Полный Fine-Tuning** - Классический подход, при котором все веса предобученной модели обновляются на целевом наборе данных. Дает хорошие результаты, но требует больших вычислительных ресурсов и памяти.
- ii. **Parameter-Efficient Fine-Tuning (PEFT)** - Группа методов, позволяющих адаптировать LLM, дообучая лишь долю от исходных параметров.
 1. Процесс продолжения обучения LLM на новых, часто узкоспециализированных данных (медицинских, юридических). В отличие от fine-tuning, здесь не меняется "поведение" модели под конкретную инструкцию, а расширяется её фундаментальное понимание предметной области.
 2. **Один из самых популярных методов PEFT.** В его основе лежит идея низкоранговой

декомпозиции.




iii. **Retraining (aka Continuous Pre-training) -**

Процесс продолжения обучения LLM на новых, часто узкоспециализированных данных (медицинских, юридических). В отличие от fine-tuning, здесь не меняется "поведение" модели под конкретную инструкцию, а расширяется её фундаментальное понимание предметной области.

34. Генеративные технологии искусственного интеллекта. Обработка естественного языка (задача NLP). Большие языковые модели. Encoder-only трансформеры. BERT. Особенности архитектуры, обучения и регуляризации. Типичные задачи.

- a. **Encoder-only** - Анализирует текст в обоих направлениях. Нужен для задач понимания смысла и контекста.

i.



ii. Использует только энкодерную часть Трансформера. Это "понимающая" модель, которая анализирует текст в обоих направлениях (слева направо и наоборот), что позволяет улавливать полный контекст слова.

iii.

Математика входа и выхода: На вход модели BERT подается последовательность эмбеддингов $x = x_1, x_2, \dots, x_n$. Ключевой финальный выход — это контекстуализированный вектор $c \in \mathbb{R}^{n \times d}$ (где n — длина последовательности, d — скрытая размерность), который присваивается специальному токenu [CLS]. Этот вектор агрегирует в себе смысл всего предложения и используется для задач классификации⁴. На этапе предобучения для токена [CLS] вычисляется вероятность:

$$P(y|X) = \text{softmax}(W \cdot C_{[CLS]} + b)$$

Формальное определение:

iv. Обучение:

1. **Masked Language Model (MLM)**: 15% слов в тексте случайно заменяются на маску, и модель учится предсказывать эти слова по окружающему контексту с обеих сторон.
2. **Next Sentence Prediction (NSP)**: Модели даются два предложения, и она учится предсказывать,

является ли второе предложение следующим за первым в исходном тексте.

3. **Дообучение (Fine-tuning):** Предобученный BERT адаптируется под конкретную задачу (например, классификацию текста). Для этого над энкодером надстраивается дополнительный классификационный слой, инициализируемый случайно, и вся модель дообучается на целевом датасете.

v. Архитектура:

1. **Multi-Head Self-Attention:** Это "двунаправленное" внимание, которое не использует маскирования, чтобы токены могли взаимодействовать друг с другом в обе стороны.
2. **Add & Norm:** Остаточная связь (сложение входа и выхода подслоя) и Layer Normalization.
3. **Feed-Forward Network (FFN):** Та самая полносвязная сеть, описанная выше.
4. **Add & Norm:** Ещё одна операция суммирования и нормализации.
5. В конце стека энкодеров **формируется финальное представление для каждого токена**, которое уже впитало в себя контекст всего предложения.

vi. Методы регуляризации:


1. **Dropout:** Случайное "выключение" нейронов с вероятностью (обычно $p=0.1$) во всех слоях: после эмбедингов, внутри слоя внимания и после FFN.

2. **Layer Normalization**: Стабилизирует и ускоряет обучение, нормализуя активации по размерности скрытого слоя.

vii. **Выполняет задачи:**

1. **Классификация текста** (анализ тональности, определение тематики).
2. **Извлечение именованных сущностей (NER)** - модель определяет, какие слова относятся к именам, локациям, датам и т.п.
3. **Извлечение ответов на вопросы (Extractive QA)** - предсказывает начальную и конечную позиции ответа в тексте.
4. **Семантический поиск и кластеризация** - векторы предложений используются для сравнения по смыслу.

35. Генеративные технологии искусственного интеллекта. Обработка естественного языка (задача NLP). Большие языковые модели. Decoder-only трансформеры. GPT. Особенности архитектуры, обучения и регуляризации. Типичные задачи.



a.

- i. **Использует только декодерную часть Трансформера.** Это генерирующая модель. Она читает текст только слева направо и учится предсказывать следующее слово в последовательности (авторегрессивно).
- ii. **Обучение:** на большом корпусе текстов для предсказания следующего слова. После предобучения модель можно дообучить (finetune) на конкретной задаче, добавив небольшой слой сверху, без изменения всей архитектуры.

iii.

Математическое описание: Процесс генерации можно описать как максимизацию вероятности последовательности с помощью правила цепочки:

$$P(x_1, x_2, \dots, x_n) = \prod_{t=1}^n P(x_t | x_1, x_2, \dots, x_{t-1}) = \prod_{t=1}^n \text{softmax}(W \cdot h_t + b)_{x_t}$$

, где h_t (скрытое состояние на шаге t) вычисляется на основе всех предыдущих токенов. Модель шаг за шагом предсказывает распределение вероятностей для следующего токена.

Формальное определение:

iv. **Регуляризация:** в основе те же механизмы, что и у BERT (Dropout и Layer Normalization), но с поправкой на архитектуру. В современных LLM также активно применяется Weight Decay (L2-регуляризация), которая добавляет штраф за большие значения весов и предотвращает переобучение (L1 - зануляет).

v. **Архитектура:**

1. **Masked Multi-Head Self-Attention:** Ключевое отличие от BERT! Используется каузальная (треугольная) маска, которая запрещает токеноу "смотреть" на будущие токены, обеспечивая авторегрессионное свойство
2. **Add & Norm:** Аналогично BERT.
3. **Feed-Forward Network (FFN):** Стандартный блок.
4. **Add & Norm:** Аналогично BERT

36. Генеративные технологии искусственного интеллекта. Обработка естественного языка (задача NLP). Большие языковые модели. Encoder-Decoder трансформеры. T5. Особенности архитектуры, обучения и регуляризации. Типичные задачи.


a. **И энкодер, и декодер.** Кодер читает вход, декодер пишет выход. Стандарт для задач трансформации последовательностей (seq2seq).

b. **Выполняемые задачи:**

- i. Машинный перевод.
- ii. Суммаризация (сжатое переложение длинного текста).
- iii. Трансформация стиля текста (переписывание текста в другом стиле)
- iv. Text-to-SQL, Text-to-Code и другие преобразования естественного текстового запроса в формализованный текст.

c. T5 (Text-to-Text Transfer Transformer):

i.



- ii. Унифицированная модель, которая приводит все NLP-задачи к формату "текст-в-текст".
- iii.

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}} + B_{\text{rel}}\right) V$$

, где B_{rel} — это матрица обучаемых весов, зависящая от относительной позиции токенов $(i-j)$.

Формальное определение:

1. Модуль Relative Positional Embeddings): вместо абсолютных синусоидальных эмбеддингов T5 добавляет скалярный вес к логитам внимания, что улучшает обработку длинных последовательностей.

iv. Архитектура:

- 1. Энкодер:** Полностью идентичен BERT. Это стек блоков с обычным, двунаправленным вниманием.
- 2. Декодер:** Аналогичен GPT, но с одной важной добавкой. Это стек блоков, каждый из которых содержит маскированное самовнимание (как у GPT), а после него - блок перекрестного внимания (CrossAttention), который позволяет декодеру "подсматривать" в выход энкодера на каждом шаге генерации.
- 3. Positional Embeddings:** Использует относительное позиционное кодирование, где к матрице внимания добавляется обучаемое смещение в зависимости от расстояния между токенами.

v. Методы обучения

- 1. Предобучение:** Использует задачу Span Corruption ("порча отрезков") - продвинутый вариант MLM. Из текста удаляются целые отрезки токенов, и модель учится восстанавливать их как единую последовательность.
- 2. Адаптация под задачи:** T5 не требует архитектурных изменений. Для любой задачи (перевод, суммаризация) на вход просто подается текст с префиксом (например, summarize), и модель генерирует ответ как текст.
- 3. Методы регуляризации:** T5 использует те же механизмы, что и BERT/GPT (Dropout, Layer Normalization, Weight Decay). Уникальной особенностью является применение label smoothing в функции потерь (сглаживание "истинных" меток), чтобы модель не становилась слишком самоуверенной в своих предсказаниях.

37. Генеративные технологии искусственного интеллекта.
Обработка естественного языка (задача NLP).
Модификация языковых моделей. Аугментация данных.
Промпт-инжиниринг. RAG.

a. Аугментация данных, промпт-инжиниринг и RAG относятся к модификации языковых моделей.

b. Обучение с подкреплением на основе человеческой обратной связи - RLHF (Reinforcement Learning from Human Feedback)

- i. Трехэтапный метод тонкой настройки** для согласования модели с человеческими предпочтениями (полезность, честность, безвредность)
- ii. Supervised Fine-Tuning (SFT):** Модель дообучается на качественных ответах, написанных людьми.
- iii. Обучение модели вознаграждения (Reward Model):** Генерируется несколько ответов модели на один промпт. Люди ранжируют их от лучшего к худшему. На этих данных учится отдельная модель, предсказывающая "вознаграждение" (рейтинг) для ответа.
- iv. Proximal Policy Optimization (PPO):** Основная LLM оптимизируется с помощью алгоритма PPO так, чтобы генерировать ответы, максимизирующие вознаграждение от модели из п.2.

c. Методы аугментации данных в NLP

- i. Замена слов на синонимы** (с использованием WordNet или BERT), случайная вставка, удаление или перестановка слов. Это повышает устойчивость модели к опечаткам и разным формулировкам.
- ii. Обратный перевод (Back-translation):** Текст переводится на иностранный язык, а

затем обратно на исходный. Это создает семантически идентичный, но грамматически и лексически разнообразный текст ("парафраз").

iii. **Генерация данных:** Использование более слабых моделей или самого LLM для создания дополнительных обучающих примеров для целевого домена.

d. **Промпт-инжиниринг** - Искусство составления инструкций (промπτов) для LLM, чтобы получить желаемый ответ без изменения весов модели. Включает few-shot (несколько примеров в промπτе) и chain-of-thought (побуждение модели рассуждать "шаг за шагом").

e. **RAG (Retrieval-Augmented Generation)** - Фреймворк, который подключает LLM к внешнему хранилищу знаний (базе данных, корпусу документов). При получении запроса RAG сначала ищет релевантные документы, а затем передает их вместе с запросом в LLM. Это позволяет модели давать ответы, основанные на фактах, не раздувая её размер и решая проблему "галлюцинаций"

i. Алгоритм работы:

1. **Пользовательский запрос** подается в компонент-ретривер.
2. **Ретривер ищет** во внешней базе знаний наиболее релевантные фрагменты.
3. Найденные фрагменты и исходный запрос **объединяются в расширенный промπτ**
4. **LLM генерирует ответ**, опираясь на предоставленный контекст

38. Генеративные технологии искусственного интеллекта. Обработка естественного языка (задача NLP). Метрики оценки качества языковых моделей. Стандартные метрики классификации. TF-IDF. Perplexity. BLEU.

a. Стандартные метрики классификации: Accuracy, Precision, Recall, F1 и т.п. (требуют эталонной разметки класса ответа).

		Predicted			
		+	-		
Actual	+	TP Type II error	FN Type I error	Sensitivity (recall) TP/●	False negative rate FN/●
	-	FP Type I error	TN	False positive rate FP/●	Specificity TN/●
		Precision TP/■	False omission rate FN/■	Accuracy (TP + TN)/(● + ■)	
		FDR FP/■	Negative predictive value TN/■	F ₁ score 2TP/(2TP + FP + FN)	

1. TF (Term Frequency — частота термина)

Определяет, как часто слово встречается в конкретном тексте.

$$\text{Формула: } TF = \frac{\text{Количество упоминаний слова}}{\text{Общее число слов в документе}}$$

2. IDF (Inverse Document Frequency — обратная частота документа)

Оценивает уникальность слова по всей базе документов. Если слово встречается почти во всех текстах (например, предлоги, союзы), его IDF стремится к нулю.

$$\text{Формула: } IDF = \ln\left(\frac{\text{Общее количество документов}}{\text{Количество документов с этим словом}}\right)$$

TF-IDF

b.

i. Оценивает важность слова в контексте конкретного документа относительно целой коллекции или корпуса текстов

$$PPL = \exp\left(-\frac{1}{N} \sum_{i=1}^N \log p_{\theta}(w_i | w_{<i})\right)$$

Perplexity (Перплексия, PPL):

c.

i. **Экспонента от средней кросс-энтропии.**

Измеряет, насколько хорошо модель предсказывает следующий токен.

ii. где: $p\theta(w_i | w_{<i})$ - вероятность, которую модель присвоила правильному слову w_i .

P.S.: Чем ниже перплексия, тем лучше модель предсказывает текст.

d. Оценивает качество машинного перевода, сравнивая машинный перевод с одним или несколькими эталонными человеческими переводами на основе точности n-грамм. Имеет штраф за слишком короткие переводы (brevity penalty).

$$BLEU = BP \cdot \exp\left(\sum_{n=1}^N w_n \log p_n\right)$$

BLEU (Bilingual Evaluation Understudy)

i. Алгоритм делит текст на «n-граммы» - последовательности из n слов. Он проверяет совпадения по словам (1-граммы), по парам слов (2-граммы) и более длинным фразам, рассчитывая Precision (какая доля слов и фраз из машинного перевода присутствует в эталонном тексте). Выражается в числе от 0 до 1 (иногда от 0 до 100).

ii.

$$BP = \begin{cases} 1, & \text{если } c > r \\ \exp\left(1 - \frac{r}{c}\right), & \text{если } c \leq r \end{cases}$$


Штраф за краткость (Brevity Penalty, BP)

где: c - длина переведенного текста (количество слов в гипотезе); r - эффективная длина эталонного текста (длина наиболее близкого по длине эталона).

The diagram illustrates four types of METEOR matching between a reference word and a candidate word, each with a corresponding score:

- Exact Match:** The reference word "cat" matches the candidate word "cat" exactly. Score: 1.0.
- Stem Match:** The reference word "running" matches the candidate word "runs" based on their common stem "run". Score: 0.9.
- Synonym Match:** The reference word "quick" matches the candidate word "fast" as they are synonyms. Score: 0.8.
- Paraphrase Match:** The reference word "give up" matches the candidate word "surrender" as they are paraphrases. Score: 0.7.

e.



i. **Вместо n-грамм сравнивает контекстные эмбединги слов из модели BERT**, что позволяет оценивать семантическое сходство, а не просто лексические совпадения. Выполняет вычисления сходства с использованием контекстуализированных векторных

представлений токенов, которые эффективны для обнаружения логического следования.

ii. **Алгоритм работы:**

1. **Контекстные векторные представления:**

эталонные и кандидаты представляются с использованием контекстных векторных представлений, основанных на окружающих словах, вычисленных такими моделями, как BERT, Roberta, XLNET и XLM.

2. **Косинусное сходство:** между контекстными векторными представлениями эталонного и потенциального предложений измеряется с помощью косинусного сходства.

3. **Сопоставление токенов для точности и полноты:** каждый токен в предложении кандидата сопоставляется с наиболее похожим токеном в эталонном предложении и наоборот, чтобы вычислить полноту и точность, которые затем объединяются для расчета показателя F1.

4. **Взвешивание по важности:** важность редких слов учитывается с помощью обратной частоты документа (IDF), которая может быть включена в уравнения BERTScore, хотя это необязательно и зависит от предметной области.

5. **Базовое масштабирование:** значения BERTScore масштабируются линейно для улучшения читаемости.

ЗАНЯТИЕ №6

39. Эволюционные вычисления. Системы интеллектуальных агентов. Агенты как искусственный интеллект. Свойства агентов. BDI-модель. Виды интеллектуальных агентов.

а. Эволюционные алгоритмы: подразумевает стратегию эволюции, работает с векторами действительных чисел в качестве представлений решений и обычно использует самоадаптирующиеся скорости мутаций, в основном используется для численной оптимизации, хотя есть и варианты для комбинаторных задач.

а. Системы интеллектуальных агентов – как ИИ -
автономные программные системы на базе искусственного интеллекта, способные воспринимать окружающую среду, самостоятельно ставить цели, планировать действия и использовать внешние инструменты для их выполнения. Они не просто отвечают на запросы, а решают сложные многоэтапные задачи.

Свойства:

і. Обучаемость (способность самостоятельного решения однотипных задач без использования базы знаний и/или способность компенсировать неточные или недостоверные данные от других агентов или базы знаний – *то есть как бы не менялись входные данные, если один раз научили задачу – мы будем решать эту задачу, продолжать учиться на новых данных*)

ii. **Автономность** (способность решать задачу *и обучаться* даже в нетривиальных условиях без вмешательства человека – *сама запускает нужные процессы и выполняет задачу без вмешательства человека*);

iii. **Реактивность** (оперативная реакция на изменение среды – идет наряду с про-активностью – *любой агент пассивно способен реагировать на изменение среды – фиксация этого факта, постройка плана дальнейшей работы*);

iv. **Про-активность** (целеполагание и поиск оптимального решения – *из всех возможных сценариев изменения среды на систему, агент выбирает лучшее из решений для дальнейшей работы*);

v. **Социальность** (особенно в многоагентных системах - взаимодействие с другими агентами для достижения собственных и общих целей, главным образом, посредством передачи сообщений с запросом и предоставлением информации – *сигнал как способ передачи информации другим агентам, должна быть между ними как дружелюбность, так и конкурентность (например, плохой промпт – быстрое выполнение задачи не так, как хочет инженер)*);

1. **Кооперативность** (способность агентов объединяться для совместного решения задачи – *система вида «Царь горы» – агенты разбиваются на команды, и конкурируют с другой командой*);
2. **Конкурентность** (способность агентов противостоять друг другу для выполнения только собственных интересов – *это не противоречивость, агенты не врут друг другу, при получении неправильной информации передает ее другим агентам*).

vi. **Мобильность** (способность агентов перемещаться внутри среды, например, в иерархии агентов, в некоторой матрице или в n-мерном виртуальном пространстве – *подсвойство проактивности, активные может переходить в когнитивную фазу и наоборот и т.д.*);

vii. **Правдивость** (агент не может специально сообщить неправдивую информацию – *сказано ранее*);

viii. **Наличие системы знаний** (наличие у агентов модели представления знаний и собственных оперативных знаний на её основе – *у агентов должны быть свои небольшие локальные базы знаний, оперативные необходимые знания должны быть под рукой*);

ix. **Рациональность** (логическая последовательность действий в рамках своих

убеждений и знаний и оптимальное взаимодействие с другими агентами – *агент должен логически следовать своим убеждениям*)

b. **BDI-модель (Beliefs, Desires, Intentions)** - основана на теории практического человеческого мышления Майкла Братмана (любой человек живет в мире исходя из убеждений, из этого формируются желания, из этого появляются намерения).

- i. **Убеждения** - информационное состояние агента (то есть знания об окружающем мире), они хранятся в базе знаний системы, в базе самого агента или базах других агентов;
- ii. **Желания** - элементы мотивации агента, то есть некоторые детерминированные (определённые) действия для достижения конечной цели (найти наиболее короткий путь от одной точки, до другой, достичь вершины иерархии, передать важное приватное сообщение определённому агенту и т.п.), при этом цели не должны быть конфликтующими (например, создать и удалить запись одновременно);
- iii. **Намерения** - конкретные решения (план действий или уже совершённые действия) для выполнения желаний, план действий может представлять собой конкретный воспроизведённый самим агентом алгоритм (например, построенный граф состояний или

дерево решений), при этом планы могут динамично изменяться во время их выполнения (главным образом, из-за свойств активности и про-активности)

с. Виды агентов

i. **Пассивные** - агенты, не имеющие целей и не следующие BDI-модели, как правило, существуют в качестве инструментов, посредников или помех для других агентов в системе;

ii. **Активные** (агенты, имеющие простые и быстро достижимые цели вроде передачи сообщений, выполнения мобильных действий и простых вычислений);

iii. **Когнитивные** (агенты, выполняющие сложные, трудоёмкие и долгие по времени вычисления и являющаяся интеллектуальным центром системы, а также основным потребителем и наполнителем базы знаний)

40. Эволюционные вычисления. Системы интеллектуальных агентов. Агенты как искусственный интеллект. Моно- и мультиагентные системы, их архитектуры. Задачи интеллектуальных агентов.

a. **Системы с одним агентом** - системы, в которых существует только один супер-агент, который также может являться и средой.

i. **Сильные стороны:** простая архитектура, низкая задержка, легкость отладки;

ii. **Слабые стороны:** плохо справляется со сложными задачами, требующими разнородных экспертных знаний, склонна к перегрузке контекста, ошибка единственного агента означает сбой всей системы.

b. **Многоагентные системы** - Система с множеством агентов, которые могут совместно или конкурентно решать задачу, симулируя реальные процессов.

i. **Сильные стороны:** каждый агент - эксперт в своей узкой области, что повышает качество решения сложных задач, система устойчива к сбоям и легко масштабируется под новые задач;

ii. **Слабые стороны:** более высокая сложность разработки и накладные расходы на коммуникацию между агентами и оркестратором (когнитивным агентом)

c. **Задачи агентов**

i. **Автоматизация** и автономность исследований и решения задач;

ii. **Оптимизация** (поиск наилучшего или близкого к нему значения некоторой целевой функции);

iii. **Поиск** наиболее выгодного или оптимального состояния некоторой системы;

iv. **Симуляция** процессов (в основном реальных социальных процессов и многофакторных событий)

d. Проблемы ИИ

- i. Представление знаний (начало 3 лекции);
- ii. Рассуждение и решение проблем;
- iii. Восприятие;
- iv. Планирование и принятие решений;
- v. Обучение;
- vi. Обработка естественного языка;
- vii. Социальный интеллект;
- viii. Обобщенный (сильный) интеллект.

41. Эволюционные вычисления. Системы интеллектуальных агентов. Агенты как инструменты машинного обучения. Общее определение. Свойства генеративного ИИ-агента.

a. **Агенты как инструменты машинного обучения** - Системы, которые на основе генеративных моделей способны автономно решать сложно структурированные, многошаговые задачи.

i. В отличие от обычных чат-ботов, *агенты не просто генерируют ответ, а планируют последовательность действий, взаимодействуют с внешними инструментами (например, базами данных, API, программным кодом) и анализируют полученные результаты, корректируя свое поведение в реальном времени.*

ii. *Агенты - не пассивные генераторы текста*, а активные исполнители, способные самостоятельно достигать поставленной цели (за счёт BDI-модели, своих свойств, среды и других агентов).

b. **Свойства генеративных ИИ-агентов** – Ключевое отличие: в безагентном режиме вся логика запрограммирована разработчиком, агент самостоятельно принимает решения.

i. **Восприятие (Perceive):** Агент получает задачу от пользователя и собирает начальный контекст;

ii. **Планирование (Plan):** LLM анализирует запрос и формирует пошаговый план действий, например: "Сначала найти данные, затем проанализировать их, потом создать отчет";

iii. **Действие (Act):** Агент выполняет запланированный шаг, используя инструменты, это может быть обращение к поисковой системе, запуск кода для анализа данных, запрос к базе данных или обращение к другому API;

iv. **Наблюдение и адаптация (Observe & Adapt):** Агент получает результат своего действия (например, данные от API или ошибку выполнения кода), LLM анализирует этот результат и решает, что делать дальше: перейти к следующему шагу плана,

скорректировать план из-за ошибки или сформулировать финальный ответ;

v. **Завершение (Finalize):** Цикл повторяется до тех пор, пока задача не будет выполнена, после чего пользователю предоставляется итоговый результат.

42. Эволюционные вычисления. Системы интеллектуальных агентов. Задачи и инструменты NLP, text-to-text.

a. Выполняемые задачи:

i. **Обработка естественного языка (NLP)** - Агентная архитектура переводит NLP от простой генерации текста к решению задач, требующих многошаговых рассуждений и работы с внешними источниками.

ii. **Исследование и анализ:** параллельная обработка текста и задач (поиска, исследования и составления ответа);

iii. **Инструменты:** для реализации NLP-агента (например, диалоговой системы) используются **LangChain** для создания агентов с инструментами (*упрощает интеграцию ИИ с базами данных, документами и внешними сервисами, позволяя разработчикам собирать сложные ИИ системы из цепочек готовых модулей, применяется при создании RAG-систем,*

чатботов и интерфейсов LLM), **LangGraph** для управления сложными процессами и памятью (строит логику приложения в виде графа состояний, где шаги ИИ могут ветвиться, зацикливаться (нужно принимать решения на основе результатов выполнения: делать шаг, проверять ответ, корректировать его при ошибке и снова отправлять модели) и возвращаться назад, также применяется при реализации многоагентных систем), а также векторные базы данных для реализации **RAG** и **ReAct** (парадигма, которая позволяет решать сложные задачи, чередуя внутренние рассуждения с выполнением действий, нужен, когда языковой модели недостаточно только её базовых знаний, и ей необходимо выполнять пошаговые рассуждения, комбинируя их с использованием внешних инструментов);

- b. **Системы типа Text-to-Text (текст-в-текст)** — это нейросети, которые принимают текстовый запрос (промпт) и генерируют осмысленный связный текст на его основе.

43. Эволюционные вычисления. Системы интеллектуальных агентов. Задачи и инструменты text-to-image, text-to-audio/voice, text-to-video.

а. Мультимедиа (изображение, звук, видео) - Агентная архитектура позволяет обеспечивать мультимодальную обработку мультимедиа и/или одновременно выполнять разные задачи относительно одной модальности разными агентами (например, одновременная сегментация и классификация видео).

i. Основные концепции

многомодальностей:

- 1. Early fusion** - данные разных модальностей объединяются сразу после первичной обработки или даже на уровне сырых признаков, и только затем подаются в единую модель (например, в VisualBERT);
- 2. Middle Fusion** - признаки модальностей сначала обрабатываются независимыми кодировщиками, а затем обмениваются информацией на протяжении нескольких промежуточных слоёв (наиболее гибкий метод), прежде чем принять финальное решение (например, ViLBERT, LXMERT и LLaVA);
- 3. Late Fusion** - каждая модальность обрабатывается полностью независимой моделью вплоть до последнего этапа (например, CLIP, ансамбли, RAG), где их финальные представления или предсказания объединяются в итоговый результат.

ii. Инструменты:

1. Платформа **n8n** с **LangChain**-агентами с **API** для создания видео и аудио (например, **Wavespeed.ai** и **Fal.ai**);
2. Готовые open-source фреймворки **Mora** (мультиагентный аналог **Sora**) и **FilmAgent** (автоматизация кинопроизводства) для задач text-to-video;
3. Специализированные ИИ-инструменты: **Luma Agents** (мультимодальный контент).

44. Эволюционные вычисления. Системы интеллектуальных агентов. Задачи и инструменты text-to-sql.

- a. **Обработка табличных данных** - Агентная архитектура позволяет взаимодействовать с данными на естественном языке (*выполнение пайплайна поиска в табличных данных по промпту*), главная задача - превратить вопрос пользователя в корректную инструкцию для базы данных (Text-to-SQL).

- i. **Бизнес-аналитика и бизнес-интеллект** (Business Intelligence): **самостоятельный сбор** (data collection), **агрегация, анализ и вывод** статистической и бизнес-информации.

- ii. **Инструменты:** **LangChain** с **SQLDatabaseToolkit** и/или **create_sql_query_chain**.

iii. **Типовые решения:** Microsoft Fabric Data Agent, Google BigQuery Agent Catalog и ExelAutomatic.

ПРАКТИЧЕСКИЕ ЗАДАНИЯ

45. Опишите план работ и пример использованных методов при предварительной обработке малого разреженного табличного набора данных с наличием экстремальных, сильно отклоняющихся от медианы, моды и средних значений атрибутов (признаков).

Предобработка малого разреженного табличного набора с экстремальными значениями

План работ:

1. Анализ структуры данных.
 - Оценка доли пропусков по признакам, разреженности, типов признаков (числовые, категориальные, бинарные).
 - Выявление экстремальных значений через статистики: медиана, мода, среднее, межквартильный размах, z-score.
2. Работа с пропусками и разреженностью.
 - Удаление признаков с чрезмерной разреженностью (например, более 80–90% пропусков), если они не информативны.
 - Импутация пропусков: для числовых – медиана или регрессионная/knn-импутация, для категориальных – мода или предсказание по простым моделям.
3. Обработка выбросов и экстремальных значений.
 - Тримминг или winsorization: обрезка значений за пределами, например, 1-го и 99-го перцентилей.
 - Робастное масштабирование: RobustScaler или нормализация относительно медианы и межквартильного размаха, чтобы снизить влияние выбросов.

4. Нормализация и кодирование признаков.
 - Масштабирование числовых признаков (StandardScaler, MinMax) после обработки выбросов.
 - Кодирование категориальных признаков: one-hot, target encoding, frequency encoding – в файле отдельно обсуждаются one-hot и другие кодировки в NLP-контексте, но их идея переносима на табличные данные.
5. Первичная проверка качества.
 - Визуализация распределений до/после предобработки (гистограммы, box-plots).
 - Обучение простой модели (DNN, random forest, logistic regression) на очищенных данных и сравнение метрик до/после.

Пример методов: RobustScaler + winsorization для числовых признаков, knn-импутация пропусков, one-hot для категориальных, затем проверка на классических моделях (DNN, Random Forest, GMM/SVM/k-NN, которые перечислены в теории).

46. Приведите пример инструментов, которые необходимо применить, чтобы создать искусственный табличный набор данных, содержащий преимущественно категориальные признаки, и оценить качество созданного набора данных с помощью методики TSTR и субъективных метрик.

Синтетический табличный набор с категориальными признаками и оценка TSTR

Инструменты для генерации:

- Генеративные табличные модели: CTGAN/TGAN, TVAE, TabDDPM, Copula-based и SMOTE-подходы для категориальных/смесевых данных – все они перечислены в разделе о табличной генерации.
- Подходы:

- CTGAN/TGAN – GAN для табличных данных с категориальными признаками.
- TVAE – вариационный автокодировщик для табличных данных.
- TabDDPM – диффузионная модель для таблиц.
- Copula + дискретизация категориальных признаков, либо SMOTE для классов с редкими категориями.

Пайплайн:

1. Подготовка исходных данных: очистка, кодирование категориальных признаков (one-hot/embedding), баланс классов.
2. Обучение табличной генеративной модели (например, CTGAN или TVAE) на исходной выборке.
3. Генерация синтетического табличного набора, преимущественно категориального.
4. Оценка качества по TSTR (Train on Synthetic, Test on Real):
 - Обучить классификатор/регрессор на синтетических данных.
 - Проверить качество на реальных данных (accuracy/F1/AUC и т.п.).
 - Сравнить с обучением на реальных данных (TRTR) и на смешанных данных.

Субъективные метрики:

- Визуальный и статистический анализ:
 - Сравнение распределений категорий (частот) между реальными и синтетическими признаками.
 - Проверка логичности сочетаний категорий (по бизнес-логике).
 - Оценка пригодности синтетических данных для аналитических задач через экспертный обзор.

47. Приведите пайплайн анализа табличного набора данных, в котором нужно построить дашборд с отображением взаимной зависимости числовых признаков и их нерегулярностей, баланс классов категориальных признаков, а также общий график распределения всех признаков в двумерном пространстве.

Пайплайн анализа табличного набора и дашборд

Нужно: взаимные зависимости числовых признаков и нерегулярности, баланс классов категориальных признаков, общий график распределения всех признаков в 2D.

Пайплайн:

1. Загрузка и предобработка данных.
 - Очистка пропусков, кодирование категориальных признаков.
 - Базовые статистики: среднее, медиана, дисперсия, выбросы.
2. Анализ числовых признаков.
 - Матрица корреляций и парные scatter-plots для числовых признаков (взаимная зависимость).
 - Выявление нерегулярностей: гистограммы, box-plots, анализ сезонности/кластеров, локальных плотностей (используя, например, GMM или DBSCAN/AGNES/STING для выявления кластеров/аномалий, которые перечислены в файле).
3. Анализ категориальных признаков.
 - Частоты категорий, визуализация баланса классов (bar-charts, stacked bars).
 - Проверка дисбаланса (перекошенных классов) и решение через ресемплинг (SMOTE для табличных, Random Forest Distribution и др.).
4. 2D-представление всех признаков.
 - Применение метода снижения размерности (PCA, t-SNE, UMAP) для всех признаков (после кодирования категориальных).
 - Построение scatter-plot в двумерном пространстве с цветовым кодированием классов/кластеров.

5. Построение дашборда.

- Использовать BI-инструменты (в теории есть упоминание Business Intelligence и текст-to-SQL): например, Power BI, Tableau, или web-дашборд на Plotly/Dash.
- Включить:
 - Матрицу корреляции и scatter-plots для числовых признаков.
 - Бар-чарты баланса категорий.
 - 2D-scatter по результатам снижения размерности.

48. Приведите пример инструментов и пайплайн, которые необходимо применить, чтобы создать искусственный табличный набор данных, содержащий преимущественно числовые признаки с высокой локальной плотностью данных, и проверить созданный набор данных с помощью методики TSTR и субъективных метрик.

Синтетический табличный набор с числовыми признаками высокой локальной плотности и TSTR

Инструменты генерации:

- TabDDPM (диффузионная модель для таблиц) – хорошо подходит для моделирования сложных локальных плотностей.
- GAN для табличных данных (TGAN/CTGAN) – генеративно моделирует плотные регионы.
- TVAE – вариационный автокодировщик для многомерных числовых распределений.

- Copula-модели и GMM/BGM для сложных многомерных распределений (есть в разделе Copula, GMM/BGM).

Пайплайн:

1. Анализ локальной плотности данных.
 - Применить GMM или кластеры (k-means, DBSCAN, AGNES, STING), чтобы выявить области высокой плотности.
 - Проверить распределения числовых признаков.
2. Обучение генеративной модели.
 - Обучить TabDDPM или TVAE/CTGAN на исходной числовой выборке.
 - Учесть локальные плотности (например, через условную генерацию или кластер-специфические модели).
3. Генерация синтетического числового табличного набора с высокой локальной плотностью.
4. Оценка TSTR.
 - Train on Synthetic, Test on Real (как в теоретическом описании TSTR): обучаем модель (DNN, Random Forest, SVM, k-NN) на синтетике, тестируем на реале.
5. Субъективные метрики.
 - Сравнение гистограмм и локальных плотностей (kernel density estimations) между реальными и синтетическими данными.
 - Экспертная оценка пригодности синтетики для реальных задач (например, прогнозов или классификации).

49. Приведите пример инструментов и пайплайн, которые необходимо применить, чтобы создать искусственные похожие друг на друга изображения или видео в реальном времени. Опишите объективные и субъективные метрики, которые вы будете применять для оценки качества генерации.

Инструменты и пайплайн для генерации похожих изображений/видео в реальном времени

Инструменты:

- Для изображений/видео в реальном времени:
 - GAN-семейство, например StyleGAN2/StyleGAN3 (для фотореалистичных лиц/объектов); BigGAN/PGGAN – другие варианты.
 - Диффузионные модели (DPM, описаны в файле) – для высококачественной генерации, но реалтайм-ограничения могут потребовать оптимизаций.
 - Для видео: text-to-video и мультимодальные системы (Mora, Sora, FilmAgent, Luma Agents – эти примеры генерации видео перечислены в файле).

Пайплайн:

1. Сбор и подготовка обучающего набора изображений/видео (data collection, pre-processing, augmentation – отдельный раздел).
2. Обучение GAN/диффузионной модели на этом наборе:
 - В случае изображений – StyleGAN/BigGAN.
 - В случае видео – специализированный GAN или диффузионная video-модель.

3. Реалтайм-инференс:

- Оптимизация модели (квантование, ускорение на GPU).
- Поточковая генерация похожих кадров/видео-фрагментов на основе входных условий.

Объективные метрики:

- FID (Fréchet Inception Distance), IS (Inception Score), PSNR и другие – прямо перечислены в разделе оценки генеративных моделей.
- FVD (Fréchet Video Distance) – для оценки качества видео (указан в теории).

Субъективные метрики:

- Оценка реализма, разнообразия и отсутствия артефактов экспертами.
- Оценка соответствия бизнес-сценарию, опрос пользователей.

50. Приведите пример инструментов и пайплайн, которые необходимо применить, чтобы отредактировать существующие изображения или видео или создать искусственные, являющиеся генерализированной интерпретаций обучающей выборки. Опишите объективные и субъективные метрики, которые вы будете применять для оценки качества.

Редактирование существующих изображений/видео и генерализованные интерпретации

Инструменты:

- Image-to-image и video-to-video модели:
 - Diffusion-based редактирование (inpainting, outpainting) и style-transfer.
 - GAN-подходы для стилизации/редактирования (CycleGAN, StyleGAN fine-tuning).
- Мультимодальные text-to-image/text-to-video системы (упомянуты: text-to-image, text-to-video, VisualBERT/ViLBERT/LXMERT/LLaVA/CLIP – для связи текста и визуала).

Пайплайн:

1. Сбор и аннотирование исходных изображений/видео (data collection, pre-processing, augmentation).
2. Обучение или дообучение модели редактирования/генерализации:
 - Подстройка StyleGAN или диффузионной модели на конкретной доменной выборке.
3. Редактирование/генерация:
 - Применение модели к входным изображениям/видео для изменения стиля, удаления/добавления объектов, генерализованных интерпретаций (обобщающие визуализации).

Объективные метрики:

- FID, IS, PSNR; для видео – FVD.
- Пиксельные метрики (SSIM, PSNR) для сравнения с эталонными кадрами.

Субъективные метрики:

- Оценка эстетики и смысловой корректности редакций экспертами.

- Опрашиваемая удовлетворённость пользователей.

51. Приведите пример инструментов и пайплайн для создания фотореалистичных искусственных изображений или видео в условиях достаточного количества видео- и оперативной памяти для обучения. Опишите объективные и субъективные метрики, которые вы будете применять для оценки качества.

GAN или диффузионная модель. Какой именно GAN - ОТВЕТИТЬ. Не подойдут вариационные автокодировщики, так как в задаче даны фотореалистичные изображения.

Фотореалистичные изображения/видео при достаточных ресурсах (GAN или DPM)

Требование: именно GAN или диффузионная модель, не VAE.

Инструменты:

- GAN:
 - StyleGAN2/3 – одно из лучших решений для фотореалистичных портретов и объектов.
 - BigGAN – для генерации разнообразных объектов высокого качества.
- Диффузионные модели (DPM – Diffusion Process Model):
 - Классы DPM, описанные в теории, могут использоваться для высококачественной генерации изображений.
- Для видео: video-GAN или video-diffusion, плюс text-to-video агенты (Mora, Sora, FilmAgent, Luma Agents).

Пайплайн:

1. Сбор большого обучающего набора (data collection), разметка, препроцессинг, аугментация.
2. Обучение мощной GAN (например StyleGAN3) или диффузионной модели на GPU-кластере, используя большие объемы VRAM и RAM.
3. Тонкая настройка под нужный домен (fine-tuning).
4. Генерация фотореалистичных изображений/видео по запросам пользователя или латентным кодам.

Объективные метрики:

- FID, IS для изображений.
- FVD, PSNR для видео.

Субъективные метрики:

- Оценка фотореализма, отсутствие артефактов, соответствие заданным атрибутам.
- Экспертная проверка в доменной области (например, медики, дизайнеры).

52. Приведите пример инструментов и пайплайн для создания аудиофайла высокого качества, содержащего синтетическую речь. Опишите объективные и субъективные метрики, которые вы будете применять для оценки качества.

Синтетическая речь высокого качества (аудиофайл)

Инструменты:

- HiFi-GAN – прямо упомянут как модель для высококачественного аудио (vocoding).

- WaveNet – генеративная модель для аудио, также перечислена в файле.
- Мультимодальные text-to-audio/voice, описанные в разделе text-to-audiovoice.

Пайплайн:

1. Подготовка корпуса речи: записанные голосовые данные, транскрипции, нормализация уровня и частоты.
2. Обучение модели TTS:
 - Модель, предсказывающая мел-спектрограммы из текста (Tacotron-подобные, не детализированы в файле, но логично вписываются).
 - Вокодер HiFi-GAN или WaveNet для получения временного аудиосигнала высокого качества.
3. Генерация синтетической речи по тексту пользователя.

Объективные метрики:

- MCD (Mel Cepstral Distortion), PESQ – прямо приведены в разделе про аудио.
- STOI, SDR (Signal-to-Distortion Ratio) – упомянуты SDR.

Субъективные метрики:

- MOS (Mean Opinion Score) – оценки естественности/понятности речи по шкале 1–5.
- Оценка интонаций, темпа, эмоций экспертами.

53. Приведите пример инструментов и пайплайн для создания аудиофайла, содержащего звуки окружающего мира или музыку (без голоса). Опишите объективные и субъективные метрики, которые вы будете применять для оценки качества.

Аудио с окружающими звуками/музыкой без голоса

Инструменты:

- GAN/диффузионные модели для аудио (музыкальные VAE/GAN, но в файле акцент на HiFi-GAN, WaveNet).
- Возможны специализированные music-VAE/GAN (логичное расширение упомянутых аудиомоделей).

Пайплайн:

1. Сбор датасета звуков окружения или музыки (без голоса): саунд-эффекты, фоновые записи, музыкальные лупы.
2. Препроцессинг: нарезка, нормализация громкости, преобразование в спектрограммы.
3. Обучение генеративной модели (GAN/диффузионная/autoencoder) для спектрограмм, далее вокодер (HiFi-GAN/WaveNet).
4. Генерация аудиофайлов по типу сцены (город, лес, море) или музыкальному стилю.

Объективные метрики:

- MCD, PESQ, SDR, возможно специфические муз. метрики (тональность, ритмика – можно измерять, но в файле конкретно упомянуты MCD и PESQ).

Субъективные метрики:

- Оценка реализма и приятности звучания слушателями (MOS).
- Экспертное мнение композиторов/звукорежиссеров.

54. Приведите пример инструментов и пайплайн для создания приложения, выполняющего классификацию и сегментацию текста в локальной базе данных в небольшой корпоративной системе в организации, не имеющий возможность устанавливать локально большие языковые модели из-за отсутствия графических серверов и отсутствия возможности их закупки и не имеющей возможность подключаться к внешним сервисам языковых моделей из-за соблюдения корпоративной тайны и неразглашения персональных данных (выборка документов небольшая и однородная).

Локальное приложение для классификации и сегментации текста без больших LLM и внешних сервисов

Ограничения: маленькая корпоративная система, нет GPU-серверов, нет внешних LLM-сервисов, база небольшая и однородная.

Инструменты:

- Классические NLP-методы: TF-IDF, bag-of-words, n-grams, линейные модели (SVM, logistic regression), Random Forest.
- Простые encoder-only модели (маленькие BERT-подобные), если CPU-мощности позволяют, но без больших LLM.

- Локальные библиотеки: scikit-learn, spaCy (классическая сегментация/токенизация).

Пайплайн:

1. Data collection: сбор корпоративных текстовых документов, очистка, токенизация, лемматизация.
2. Фичеризация: TF-IDF, возможно небольшие word2vec-эмбединги, если требуется семантика.
3. Классификация:
 - Обучение SVM/Random Forest/логистической регрессии для классификации документов по классам.
4. Сегментация текста:
 - Правила + ML-модель для выделения значимых блоков (глав, разделов).
 - Использование простых CRF или sequence-labeling моделей на основе TF-IDF/эмбедингов, но без больших LLM.

55. Приведите пример инструментов и пайплайн для создания приложения, выполняющего извлечение именованных сущностей и поиска ответов на вопросы пользователя в текстовых документах организации, имеющей достаточные вычислительные мощности для запуска небольших локальных языковых моделей, но не имеющих возможности использовать внешние сервисы языковых моделей из-за соблюдения корпоративной тайны и неразглашения персональных данных сотрудников.

Извлечение именованных сущностей и QA по документам при наличии ресурсов для небольших локальных LLM

Ограничения: есть вычислительные мощности для небольших локальных LLM, но нельзя использовать внешние сервисы.

Инструменты:

- Encoder-only модели (BERT-типа) для NER.
- Encoder-decoder или decoder-only небольшие модели (T5, GPT-подобные) – для локального QA.
- LangChain или аналогичные фреймворки для построения RAG-систем над локальной базой документов.

Пайплайн:

1. Подготовка корпуса: сбор, очистка, токенизация, индексация документов.
2. NER:
 - Обучение или fine-tuning локального BERT-моделя для извлечения именованных сущностей (организации, люди, даты и т.д.).

3. QA-система:

- Выбор локальной LLM (decoder-only или encoder-decoder) для ответов на вопросы.
- Использование RAG: индексация документов (например, через vector store), поиск релевантных фрагментов и подача их в модель для ответа.

4. Оценка:

- Метрики QA (accuracy, F1), NER (precision/recall/F1).

56. Приведите пример инструментов и пайплайн для создания корпоративного чат-бота в условиях отсутствия возможности выходить в глобальную сеть. Чат-бот должен уметь бороться с галлюцинациями и с высокой точностью находить конкретные пункты в корпоративных документах. Вычислительной мощности серверного оборудования организации достаточно для запуска нескольких больших языковых моделей с менее 10 миллиардов параметров, либо одной большой на 30+ миллиардов.

Так как речь идет про чатбот, то здесь подойдет модель Decoder-only. Либо несколько моделей поменьше, либо одна крупная.

Корпоративный чат-бот без доступа к интернету, борющийся с галлюцинациями

Ограничения: нет выхода в глобальную сеть, есть вычислительные мощности для нескольких моделей <10B параметров или одной >30B; нужна модель decoder-only.

Инструменты:

- Decoder-only LLM (GPT-подобная) – основа чат-бота.
- RAG (Retrieval-Augmented Generation) для снижения галлюцинаций: encoder-only модель (BERT) для поиска, плюс базы векторных эмбеддингов корпоративных документов.
- LangChain/LangGraph и ReAct-подходы (упомянуты в файле) для управления диалогом и инструментами.

Пайплайн:

1. Data collection: сбор корпоративных документов, очистка, структурирование.
2. Индексация:
 - Создание векторного индекса документов через эмбеддинги encoder-модели.
3. Диалоговая модель:
 - Настройка decoder-only LLM локально.
 - Подключение RAG: перед каждым ответом искать релевантные фрагменты документа и подавать их в контекст LLM, чтобы минимизировать галлюцинации.
4. Управление агентом:
 - Использовать LangGraph/LangChain, ReAct-стратегии: модель сначала «думает», выбирает инструмент (поиск в базе), потом формирует ответ.
5. Оценка:
 - Точность нахождения пунктов документа, доля корректных ссылок, снижение галлюцинаций по экспертной оценке.

57. Приведите пример инструментов и пайплайн для создания системы суммаризации и перевода текста для организации, изучающей исторические тексты античного и более ранних периодов. Ограничений по вычислительным мощностям и выхода в глобальную сеть нет. Модель должна уметь вести диалог от лица специалиста в предметной области и дообучаться на новых текстах – в том числе других культурных и языковых групп.

Какими-то инструментами придется модернизировать, модифицировать, улучшить эту языковую модель. (перед 5 занятием об этом говорили)

Система суммаризации и перевода исторических текстов, диалог от лица специалиста, дообучение

Система суммаризации и перевода исторических текстов, диалог от лица специалиста, дообучение

Ограничений по ресурсам и сети нет.

Инструменты:

- Большая encoder-decoder модель (T5-тип) или мощный decoder-only LLM (GPT-тип) для суммаризации и перевода.
- Fine-tuning, PEFT (Parameter-Efficient Fine-Tuning), retraining – методы модернизации/дообучения моделей, подробно обсуждаются в теории.
- RAG для использования внешних и локальных источников.

Пайплайн:

1. Сбор корпуса: исторические тексты античного и более ранних периодов, переводные материалы, научные статьи.
2. Базовая модель:
 - Выбор мощной LLM (decoder-only или encoder-decoder) с поддержкой многоязычности.
3. Модернизация/дообучение:
 - Использование fine-tuning/PEFT на доменном корпусе (исторические тексты).
 - Дополнительный retraining на новых текстах, в том числе других культур/языков.
4. Функции:
 - Суммаризация текстов.
 - Перевод (многоязычный).
 - Диалог от лица специалиста: настройка prompt-инструкций и дообучение на примерах диалога эксперт-студент.
5. RAG:
 - Подключение внешних источников (базы исторических текстов) для уточнения ответов.

58. Приведите пример инструментов и пайплайн для создания системы, способной самостоятельно изучать источники и создавать мультимедийный контент одной модальности на основе запроса пользователя.

**Система, самостоятельно изучающая
источники и создающая мультимедийный
контент одной модальности**

Система, самостоятельно изучающая источники и создающая мультимедийный контент одной модальности

Одна модальность за запрос, но система сама изучает источники.

Инструменты:

- BDI-агентная архитектура (Beliefs, Desires, Intentions) – подробно описана в файле как основа для систем, которые «перцептируют, планируют, действуют, наблюдают и адаптируются».
- LangChain/LangGraph для оркестрации LLM и инструментов.
- Мультимодальные text-to-image/text-to-audio/text-to-video или text-to-sql/text-to-code в зависимости от модальности.

Пайплайн:

1. Perceive:

- Система принимает запрос пользователя, определяет модальность (например, только text-to-image).

2. Plan:

- BDI-агент планирует шаги: поиск источников, извлечение информации, генерация контента.

3. Act:

- Использование LLM для анализа источников (через RAG).
- Генерация контента одной модальности:
 - Изображения – через text-to-image модель.
 - Аудио – через text-to-audiovoice.
 - Видео – через text-to-video (Mora/Sora/FilmAgent/Luma).

4. Observe/Adapt:

- Оценка результата и дообучение на новых примерах (feedback-loop).

59. Приведите пример инструментов и пайплайн для создания системы, работающей в условиях слабоструктурированных запросов пользователей и генерации контента разной модальности. Система сама должна находить источники, предлагать несколько вариантов, а менее релевантные отсекаать сама в процессе генерации.

Система для слабоструктурированных запросов и мультимодальной генерации с выбором наиболее релевантных вариантов

Система для слабоструктурированных запросов и мультимодальной генерации с выбором наиболее релевантных вариантов

Слабоструктурированные запросы, контент разных модальностей, отбор менее релевантных вариантов.

Инструменты:

- Мультимодальные модели и фреймворки: text-to-image, text-to-audiovoice, text-to-video, text-to-sql, text-to-code – все перечислены.
- Early/Middle/Late fusion архитектуры (VisualBERT, ViLBERT, LXMERT, LLaVA, CLIP) для связи текста и визуала.
- BDI-агенты + LangGraph/LangChain, ReAct, RAG.

Пайплайн:

1. Парсинг слабоструктурированных запросов:

- LLM анализирует запрос, определяет потенциальные модальности и источники.
2. Поиск и отбор источников:
- RAG-модуль ищет релевантные документы/данные.
 - BDI-агент оценивает релевантность, отбрасывая явно нерелевантные источники.
3. Генерация мультимодального контента:
- В зависимости от запроса и решения агента – text-to-image, text-to-audio, text-to-video, text-to-sql, text-to-code.
4. Отсечение менее релевантных вариантов:
- Оценка по семантическому сходству (эмбединги CLIP/LLaVA).
 - Фильтрация по заданным порогам качества (например, FID для изображений, PESQ для аудио).

60. Приведите пример инструментов и пайплайн для создания системы, способной в зависимости от запроса пользователя выполнять задачи разных модальностей, но только по одной модальности за один запрос пользователя. К задачам могут относиться text-to-text, text-to-sql и text-to-code.

Система, выбирающая одну модальность (text-to-text, text-to-sql, text-to-code) в зависимости от запроса

Система, выбирающая одну модальность (text-to-text, text-to-sql, text-to-code) в зависимости от запроса

Система должна по одному запросу выполнять одну из задач: text-to-text, text-to-sql или text-to-code.

Инструменты:

- Decoder-only и encoder-decoder LLM-модели для text-to-text.
- LangChain SQLDatabaseToolkit (прямо упомянут как инструмент для text-to-SQL, createsqlquerychain и др.).
- LLM для генерации кода (text-to-code).
- Оркестратор (n8n, LangChain, Wavespeed.ai, Fal.ai – примеры инструментальных оркестраторов из файла).

Пайплайн:

1. Классификация типа запроса:
 - LLM-классификатор определяет, требуется ли text-to-text (суммаризация/перефразирование), text-to-sql (запрос к базе данных) или text-to-code (генерация скриптов).
2. Маршрутизация:
 - Оркестратор (LangChain/n8n) направляет запрос в нужный модуль:
 - Text-to-text – LLM, настроенная на диалог/суммаризацию.
 - Text-to-SQL – LangChain SQLDatabaseToolkit, создающий корректные SQL-запросы.
 - Text-to-code – LLM, обученная на коде.
3. Выполнение задачи и возврат результата пользователю.
4. Логирование и возможное дообучение на новых запросах (обратная связь).